

计算机视觉 (CV)

Computer Vision

Author: Simson

Date: September 2026

目录

1 计算机视觉简介	1
1.1 计算机视觉概念	1
1.2 计算机视觉的历史脉络 (History of Computer Vision)	1
1.3 计算机视觉概论 (Overview of Computer Vision)	2
1.4 为什么计算机视觉很难 (Why Is Computer Vision Hard?)	2
1.5 计算机视觉的发展波次 (Waves of Computer Vision)	3
1.6 本课程的内容地图 (Course Roadmap)	4
2 Image Formation	4
2.1 相机 (Camera)	5
2.1.1 为什么需要针孔	5
2.1.2 数学针孔相机模型	5
2.1.3 坐标系与外参	5
2.1.4 内参	6
2.1.5 相机参数总结	6
2.1.6 投影的性质	6
2.2 透镜 (Lens)	7
2.2.1 针孔的两难	7
2.2.2 高斯透镜公式	7
2.3 景深 (Depth of Field)	8
2.4 视场 (Field of View)	8
2.5 镜头像差与畸变 (Lens Aberrations)	8
2.5.1 径向畸变	8
2.5.2 色差	9
2.5.3 湮灭 (暗角)	9
2.6 颜色 (Colors)	9
2.6.1 人眼	9
2.6.2 CIE RGB	9
2.7 图像传感 (Image Sensing)	10
2.7.1 成像管线	10
2.7.2 快门	10
2.7.3 传感器	10
2.7.4 彩色滤镜阵列与去马赛克	11
2.7.5 Gamma 校正	11
2.8 本讲小结	11

3 Image Processing	11
3.1 逐像素处理 Pixel(Point) Processing	11
3.1.1 基本 P 图操作	11
3.1.2 Histogram Equalization	12
3.2 Filtering	13
3.2.1 线性滤波器	13
3.2.2 非线性滤波器	14
3.3 UpSampling & DownSmampling	15
3.3.1 DownSampling 和防走样	15
3.3.2 UpSampling	15

这是计算机视觉（CV）的课堂笔记，笔记参考 PPT 和课程教材，课堂 PPT 为英文，尽量写成中文版

1 计算机视觉简介

1.1 计算机视觉概念

“Make computers see.”

- 输入：光学采样（optical sampling）得到的图像、视频或其他传感器数据。
- 输出：三维场景表示和重建（3D scene representation and reconstruction），以及物体和场景的语义（semantic）。
- 目标：将光学输入转换为语义和结构，回答“图像中有什么、在哪里、是什么，以及接下来可能发生什么”。

1.2 计算机视觉的历史脉络（History of Computer Vision）

计算机视觉并不是一开始就等同于“识别图片中的物体”。它的发展始终围绕一个核心问题展开：如何把二维图像中的光照、颜色和几何信息，转换为对现实世界中物体、场景和行为的可计算理解。

1. **萌芽阶段：从成像到图像处理（Image Formation and Image Processing）**。摄影术、照相机和光学成像理论为计算机视觉提供了数据来源。计算机出现后，研究者首先关注图像的数字化、去噪、增强、边缘检测（edge detection）和分割（segmentation）等问题。这一时期的重点是回答“图像中有哪些可测量的结构”，而不是直接理解图像内容。
2. **早期人工智能阶段：把视觉看作符号推理（Symbolic Reasoning）**。20 世纪 60 年代，计算机视觉逐渐成为人工智能（Artificial Intelligence）的研究方向。早期系统尝试从线条、角点和简单几何图形中恢复物体结构，并将视觉结果交给符号系统进行推理。由于真实图像受到遮挡、噪声、光照变化和视角变化的影响，这类依赖人工规则的方法很难扩展到复杂场景。
3. **理论化阶段：视觉的多层表示（Hierarchical Representation）**。David Marr 提出视觉处理可以分为多个层次：原始图像（primal sketch）、二维半描述（2.5D sketch）以及三维模型（3D model representation）。这一观点强调，视觉不是一次性完成的分类，而是从图像证据逐步构造几何和语义表示（representation）的过程，对后来的三维重建（3D reconstruction）和场景理解（scene understanding）影响深远。
4. **经典特征阶段：从人工特征到统计学习（Hand-crafted Features and Statistical Learning）**。20 世纪 90 年代至 21 世纪初，研究者设计了 SIFT（Scale-Invariant Feature Transform）、HOG（Histogram of Oriented Gradients）等局部或区域特征，并结合支持向量机（Support Vector Machine, SVM）等分类器完成识别任务。随后出现的 Viola-Jones 人脸检测器展示了级联分类器（cascade classifier）在实际应用中的效率。这一阶段的典型流程是“特征提取（feature extraction）+ 分类器（classifier）”。

5. **深度学习阶段：学习视觉表示 (Deep Learning)**。大规模数据集、图形处理器 (Graphics Processing Unit, GPU) 和反向传播 (backpropagation) 共同推动了卷积神经网络 (Convolutional Neural Network, CNN) 的发展。2012 年 AlexNet 在 ImageNet 图像分类任务上的成功，使端到端学习 (end-to-end learning) 成为主流：模型不再完全依赖人工设计特征，而是从数据中联合学习特征和任务目标。目标检测 (object detection)、语义分割 (semantic segmentation) 和实例分割 (instance segmentation) 也因此获得了显著进步。
6. **当前阶段：视觉基础模型 (Vision Foundation Models)**。近年来，视觉 Transformer (Vision Transformer, ViT)、视觉语言模型 (Vision-Language Model, VLM) 和多模态大模型 (multimodal large model) 逐渐成为重要方向。模型可以在大规模图像、文本或视频上进行预训练 (pre-training)，再通过微调 (fine-tuning) 或提示学习 (prompting) 适应下游任务。研究重点也从单一分类任务扩展到图像生成 (image generation)、视频理解 (video understanding)、三维感知 (3D perception) 以及具身智能 (embodied intelligence)。

1.3 计算机视觉概论 (Overview of Computer Vision)

计算机视觉 (Computer Vision, CV) 研究如何使计算机从图像和视频中提取信息，并据此完成测量、识别、预测和决策。常用的概括是 “Make computers see”，但这里的 “see” 并不只是把像素读入内存，而是建立从视觉观测 (visual observation) 到世界模型 (world model) 的联系。

从信息处理的角度看，计算机视觉通常包含以下三个层次：

- **成像与感知 (Imaging and Sensing)**：通过相机 (camera)、深度传感器 (depth sensor)、激光雷达 (LiDAR) 等设备获得图像或视频。需要考虑投影模型 (projection model)、光照 (illumination)、噪声 (noise) 和相机标定 (camera calibration)。
- **表示与理解 (Representation and Understanding)**：将像素转换为边缘、关键点 (keypoint)、纹理 (texture)、物体、姿态 (pose) 和场景结构等表示，并理解物体之间的空间关系。
- **推理与行动 (Inference and Action)**：根据视觉表示完成分类 (classification)、检测 (detection)、跟踪 (tracking)、三维重建 (3D reconstruction)、预测 (prediction) 或控制 (control)。

按照任务目标，计算机视觉问题可以分为几何视觉 (geometric vision)、识别视觉 (recognition)、场景理解 (scene understanding) 和生成视觉 (generative vision) 等方向。几何视觉关注相机、点、线、平面和三维结构之间的关系；识别视觉关注 “图像中有什么”；场景理解进一步回答 “它们在哪里、如何相互作用”；生成视觉则根据图像或文本条件生成新的视觉内容。

计算机视觉与图像处理 (Image Processing)、计算机图形学 (Computer Graphics)、模式识别 (Pattern Recognition) 和机器学习 (Machine Learning) 关系密切，但关注点并不完全相同：图像处理主要改变或恢复图像，图形学主要从模型生成图像，而计算机视觉主要从图像反推出物体、场景和行为。实际系统通常会综合使用这些领域的方法。

1.4 为什么计算机视觉很难 (Why Is Computer Vision Hard?)

计算机看到的首先不是 “猫” “汽车” 或 “街道”，而是一组离散的数字。对于一张 RGB 图像 (RGB image)，每个像素通常由三个颜色通道组成，数值记录的是光在成像平面上的采样结果。计算机需要从

例如 $800 \times 600 \times 3$ 的数值矩阵中恢复物体、材质、空间位置和正在发生的动作，这中间存在明显的语义鸿沟 (semantic gap)。

此外，图像是三维世界在二维平面上的投影 (2D projection of the 3D world)。同一个物体在不同视点、光照和距离下可能产生差异很大的图像；反过来，不同的三维场景也可能投影为相同或非常相似的二维图像。因此，从图像恢复真实场景本质上是一个不适定逆问题 (ill-posed inverse problem)，通常需要引入先验知识 (prior knowledge)、物理假设 (physical assumptions) 或数据驱动的统计规律 (data-driven statistics)。

典型困难包括：

- **视点变化 (viewpoint variation)**：相机位置或观察方向变化会改变物体的外观、可见表面和投影形状。
- **形变 (deformation)**：人体、动物、布料等非刚体 (non-rigid object) 会改变姿态和局部结构。
- **遮挡 (occlusion)**：物体可能被其他物体遮住，系统只能根据不完整的观测推断整体。
- **光照变化 (illumination variation)**：阴影、反射、曝光和光源方向会改变像素值，但不一定改变物体本身。
- **运动 (motion)**：物体和相机都可能运动，导致运动模糊 (motion blur)、目标位移和对应关系变化。
- **局部歧义 (local ambiguity)**：局部纹理或轮廓可能对应多个合理解释，例如错觉图形中的边界并不唯一。
- **类内差异与类间相似 (intra-class variation and inter-class similarity)**：同一类别的物体可能外观差异很大，而不同类别的物体可能具有相似形状或颜色。

因此，视觉系统不仅要完成感知 (perception)，还要完成测量 (measurement) 和推理 (reasoning)。一个系统能够准确分类，并不意味着它已经恢复了可靠的几何结构；同样，能够测量深度的系统，也未必理解场景中的语义关系。

1.5 计算机视觉的发展波次 (Waves of Computer Vision)

按照研究问题和主要技术路线，计算机视觉的发展可以概括为以下几个阶段：

1. **启发式视觉 (1960–1970, Heuristic Vision)**：研究集中于积木世界 (blocks world)、边缘和符号人工智能 (symbolic AI)。Larry Roberts 的 Blocks World 试图从二维线条的拓扑结构推断物体的三维结构；1966 年 MIT Summer Vision Project 则体现了早期对视觉问题复杂度的低估。
2. **低层视觉 (1970–1981, Low-level Vision)**：研究者转向更基础的几何和物理问题，包括阴影形状 (shape from shading)、本征图像 (intrinsic images)、光度立体 (photometric stereo)、双目立体 (stereo)、光流 (optical flow) 和极几何 (epipolar geometry)。这些方法说明，视觉理解必须先处理图像形成和空间对应关系。

3. **神经网络萌芽 (1985–1989, Early Neural Networks)**: 反向传播算法 (backpropagation) 使基于梯度的表示学习成为可能, 早期神经网络开始用于视觉识别; 但受限于数据、算力和网络规模, 神经网络尚未成为主流。
4. **三维几何阶段 (1990–2000, 3D Geometry)**: 稠密立体 (dense stereo)、多视图立体 (multi-view stereo) 和结构光等方法不断发展, 研究重点是从多个图像恢复场景几何。
5. **特征工程阶段 (2000–2010, Feature Engineering)**: SIFT、HOG 等特征描述子 (feature descriptor) 和结构从运动 (Structure from Motion, SfM) 推动了目标识别、图像匹配和大规模照片建模。Kinect 等深度传感器也促进了三维姿态估计和机器人视觉的发展。
6. **深度学习阶段 (2010 至今, Deep Learning)**: ImageNet 提供了大规模标注数据, GPU 提供了训练深层网络的计算能力, AlexNet 在 2012 年 ImageNet 竞赛中的成功由此成为转折点。随后 VGGNet、ResNet、语义分割网络和 Mask R-CNN 等方法将学习式表示扩展到分类、检测、分割和结构化预测。

近年来, 视觉研究进一步从二维识别扩展到三维和跨模态任务。三维深度学习 (3D deep learning) 开始处理体素 (voxel)、点云 (point cloud)、网格 (mesh) 和隐式表示 (implicit representation); NeRF (Neural Radiance Field) 通过学习体渲染函数 (volumetric rendering function) 实现复杂场景的新视角合成 (novel view synthesis); 视觉语言模型 (Vision-Language Model, VLM) 则把图像与文本联系起来, 支持图像描述 (image captioning)、视觉问答 (Visual Question Answering, VQA) 和文本生成图像 (text-to-image generation)。

1.6 本课程的内容地图 (Course Roadmap)

根据计算机视觉的主要问题, 本课程可以分为三个相互联系的模块:

- **图像处理与成像 (Image Processing and Image Formation)**: 研究图像如何产生、如何表示, 以及去噪、增强、滤波、特征提取和图像拼接 (image stitching) 等基本操作。
- **三维视觉 (3D Vision)**: 研究特征与匹配 (features and matching)、从阴影恢复形状、结构从运动、双目和多视图立体重建 (stereo reconstruction) 等问题。
- **计算机视觉深度学习 (Deep Learning for Computer Vision)**: 学习机器学习基础、卷积神经网络、Transformer、表示学习 (representation learning)、目标检测和语义/实例分割。

这三个模块并不是彼此孤立的: 图像形成决定了观测数据的性质, 几何方法提供空间约束, 深度学习则可以从大规模数据中学习更加稳定的表示。一个完整的视觉系统通常需要把成像模型、几何推理和数据驱动模型结合起来。

2 Image Formation

本讲讨论图像是如何形成的: 先由最简单的针孔模型建立相机的数学描述, 再引入透镜, 最后讨论景深、视场、镜头像差、颜色和图像传感。

2.1 相机 (Camera)

2.1.1 为什么需要针孔

如果把数字传感器 (CCD 或 CMOS) 直接对着真实场景, 每个传感器像素都会接收到来自场景中几乎所有点的光线, 各种方向的光被平均在一起, 得到的图像完全模糊。问题在于没有对光线的方向施加任何限制。

针孔相机 (pinhole camera) 在传感器前放置一块不透光的挡板 (barrier/diaphragm), 上面开一个针孔 (pinhole/aperture)。绝大多数光线被挡住, 只有一条光线能穿过针孔到达传感器, 于是场景中的每个点只对应传感器上的一个像素, 图像变得清晰。

小孔成像在中国古代已有记载。《墨经·经下》: “景到, 在午有端与景长, 说在端。”《经说下》: “景。光之人, 煦若射, 下者之人也高; 高者之人也下。足蔽下光, 故成景于上; 首蔽上光, 故成景于下。在远近有端, 与于光, 故景库内也。”其中已经指出倒像 (“景到”) 的成因是光沿直线传播并被小孔限制。

日常环境中也常出现偶然的针孔相机 (accidental pinhole camera): 树叶缝隙、窗帘孔洞等会投出成像, 这些成像常常不被注意或被误认为阴影。Torralba 和 Freeman 在 *Accidental Pinhole and Pinspeck Cameras* (CVPR 2012) 中对此做了系统研究。

2.1.2 数学针孔相机模型

物理上像平面位于针孔之后, 成倒像; 为了建模方便, 通常把像平面平移到针孔之前, 此时成的是正像, 几何关系不变。设相机坐标系中物点坐标为 (x, y, z) , 像平面上的像点坐标为 (x', y') , 针孔到像平面的距离 (焦距) 为 f , 由相似三角形得

$$\frac{x'}{f} = \frac{x}{z}, \quad \frac{y'}{f} = \frac{y}{z}$$

即

$$x' = f \frac{x}{z}, \quad y' = f \frac{y}{z}$$

注意这里出现了除以 z 的运算, 因此投影并不是线性变换, 这一点后面还会展开。

2.1.3 坐标系与外参

成像过程涉及三个坐标系: 世界坐标系 (world coordinates)、相机坐标系 (camera coordinates) 和图像坐标系 (image coordinates)。

外参 (extrinsic parameters) 描述如何把世界坐标中的点 (x, y, z) 变换到相机坐标系, 包含两部分:

- 相机或物体的位置 $\rightarrow$ 平移 (translation), 3 个自由度
- 相机或物体的朝向 $\rightarrow$ 旋转 (rotation), 3 个自由度

合起来是刚体变换 (rigid transformation), 共 6 个自由度。

用齐次坐标 (homogeneous coordinates) 可以把平移和旋转统一写成矩阵乘法。齐次坐标把一个点表示为多一维的向量, 并通过最后一维归一化:

$$\mathbf{x} = (x, y, z, w) \cong \left(\frac{x}{w}, \frac{y}{w}, \frac{z}{w}, 1 \right)$$

于是平移、旋转和刚体变换分别写成

$$T = \begin{bmatrix} I_{3 \times 3} & t_{3 \times 1} \\ 0 & 1 \end{bmatrix}, \quad R = \begin{bmatrix} R_{3 \times 3} & 0 \\ 0 & 1 \end{bmatrix}, \quad M = \begin{bmatrix} R_{3 \times 3} & t_{3 \times 1} \\ 0 & 1 \end{bmatrix}$$

其中 I 为单位矩阵, t 为平移向量。下标只用于标注各块的形状, 实际书写时可以省略。

2.1.4 内参

内参 (intrinsic parameters) 描述如何把相机坐标系中的点 (x, y, z) 投影到图像平面, 本质上是图像平面内的缩放加平移, 用二维齐次坐标表示为

$$\begin{bmatrix} u \\ v \\ w \end{bmatrix} = K \begin{bmatrix} x \\ y \\ z \end{bmatrix}, \quad K = \begin{bmatrix} \alpha f & s & c_x \\ 0 & f & c_y \\ 0 & 0 & 1 \end{bmatrix}$$

矩阵最后一行的 $[0 \ 0 \ 1]$ 对应透视投影 (projective); 若换成 $[0 \ 0 \ 0 \ 1]$, 得到的是正交投影 (orthographic)。 K 中各参数的含义是:

- f : 焦距
- α : 纵横比 (aspect ratio), 像素为正方形时等于 1
- s : 倾斜 (skew), 只有当像素是平行四边形时才非零
- (c_x, c_y) : 主点 (principal point), 当光轴与图像中心相交时等于 $(w/2, h/2)$

2.1.5 相机参数总结

外参 (旋转 R 与平移 t) 和内参 K 合起来给出 3×4 的投影矩阵:

$$P = K \begin{bmatrix} R_{3 \times 3} & t_{3 \times 1} \end{bmatrix}$$

它把世界坐标中的三维点直接映射为图像平面上的二维点。

2.1.6 投影的性质

投影不是线性变换 (因为要除以 z), 但仍保留若干结构性性质:

- 点投影为点, 直线投影为直线
- 角度不被保持
- 每一组平行线交于同一个点, 称为灭点 (vanishing point)

以“直线投影为直线”为例,设三维直线由一点 $\mathbf{X}_0 = (X_0, Y_0, Z_0, 1)^T$ 和方向向量 $\mathbf{D} = (D_1, D_2, D_3)^T$ 参数化:

$$\mathbf{X}_t = \begin{bmatrix} X_0 + tD_1 \\ Y_0 + tD_2 \\ Z_0 + tD_3 \\ 1 \end{bmatrix} \cong \begin{bmatrix} X_0/t + D_1 \\ Y_0/t + D_2 \\ Z_0/t + D_3 \\ 1/t \end{bmatrix} \xrightarrow{t \rightarrow \infty} \begin{bmatrix} D_1 \\ D_2 \\ D_3 \\ 0 \end{bmatrix} = \mathbf{X}_\infty$$

把直线的参数方程代入投影矩阵并消去参数 t , 得到的是图像平面上的一条直线。

$\mathbf{X}_\infty$ 称为无穷远点 (point at infinity), 它的投影就是灭点:

$$\mathbf{v} \cong P\mathbf{X}_\infty$$

所有方向相同的直线共享同一个灭点。当灭点位于无穷远时, 对应的一组直线在图像中仍然平行。相机相对于场景的朝向决定了有几个方向的平行线在图像中汇聚, 这也就是一点透视 (one point perspective)、两点透视 (two point perspective) 和三点透视的区别。

2.2 透镜 (Lens)

2.2.1 针孔的两难

- 针孔太小: 进入的光很少, 图像很暗, 需要很长的曝光时间; 同时衍射 (diffraction) 开始起作用, 同样会使图像模糊。
- 针孔太大: 进光量增加, 图像变亮, 但每个像素会平均来自多个方向的光线, 图像失去锐度。

因此针孔相机的成像总是偏暗而且偏慢: 对于场景中的某个点, 单位时间内只有极少数光线能够到达像平面, 而针孔的大小又必须很小才能保证清晰。

2.2.2 高斯透镜公式

透镜的作用是在尽可能保持理想针孔相机抽象的同时捕获更多的光, 也就是允许使用大孔径并且仍然得到清晰的图像。

把针孔换成透镜后, 设物距为 z 、像距为 z' 、焦距为 f 。由相似三角形 $x/z = x'/z'$ 得 $x/x' = z/z'$, 再结合 $(x' + x)/f = x'/z$, 有

$$\frac{1}{f} = \frac{x' + x}{x'z} = \frac{1}{z} + \frac{x}{x'z} = \frac{1}{z} + \frac{1}{z'}$$


即高斯透镜公式 (Gaussian lens equation):

$$\frac{1}{f} = \frac{1}{z} + \frac{1}{z'}$$

当物体位于无穷远 ($z = \infty$) 时, $z' = f$, 即像距等于焦距, 这就是对无穷远对焦的情形。(在实际情况下, 由于真实相机的焦距通常非常小对于远处的物体和风景可以将物距当作无穷远进行考虑)

2.3 景深 (Depth of Field)

在焦距和像平面固定之后，只有一个特定距离上的物体是“对焦”的，其他距离的点会投影成图像平面上的一个弥散圆 (circle of confusion)。



景深 (depth of field, DOF) 定义为场景中看起来足够清晰 (acceptably sharp) 的最近物体与最远物体之间的距离。

控制景深的主要手段是光圈 (aperture) 大小：

- 光圈越小，景深越大
- 但小光圈减少进光量，需要增加曝光时间，图像噪声更大

实际拍摄中的取舍是：大光圈适合拍摄孤立主体，例如夜景或人像；小光圈提供更大的景深，适合风景、流水等题材。

2.4 视场 (Field of View)

视场 (field of view, FoV) 是相机所观测到的世界的角度范围。设传感器尺寸为 d ，像距为 z' ，视场角为 α ，则

$$\tan \frac{\alpha}{2} = \frac{d/2}{z'}$$

其中 $z' = (1 + m)F$ ， m 为放大率；对无穷远对焦时 $z' = F$ 。焦距越短，视场越大 (广角)；焦距越长，视场越小 (长焦)。感受整体的风景效果，应当采用短焦镜头增大视角。拍摄远处的东西，采用长焦镜头。

2.5 镜头像差与畸变 (Lens Aberrations)

2.5.1 径向畸变

径向畸变 (radial distortion) 由透镜不完美引起，在广角镜头中尤其明显，越靠近图像边缘越显著，表现为图像内容被压缩。负径向畸变指的是图像背离径向方向发生变形，这由于使用了超广角镜头，导致图片呈现木桶式的向外膨胀现象；正径向畸变反之，是向内陷入的现象。

建模时不再直接使用标准投影矩阵，而是分三步进行：

1. 投影到“归一化”图像坐标 (normalized image coordinates): $x_n = x/z$, $y_n = y/z$

2. 施加径向畸变:

$$x_d = x_n (1 + k_1 r^2 + k_2 r^4), \quad y_d = y_n (1 + k_1 r^2 + k_2 r^4)$$

其中 $r^2 = x_n^2 + y_n^2$, k_1, k_2 为畸变系数

3. 施加焦距并平移到图像中心: $u = f x_d + c_x$, $v = f y_d + c_y$

OpenCV 提供了标定和去畸变的实现。畸变对不同题材的影响不同: 广角适合强调透视, 标准镜头接近人眼观感, 长焦则压缩空间。

2.5.2 色差

玻璃的折射率随波长略有变化, 因此简单透镜存在色差 (chromatic aberration): 不同颜色的光聚焦在略微不同的距离上, 表现为模糊和颜色偏移。为了减弱色差和其他像差, 多数摄影镜头采用由不同玻璃元件 (以及不同镀膜) 组成的复合透镜 (compound lens)。

2.5.3 湮灭 (暗角)

湮灭, 也叫暗角 (vignetting), 指亮度向图像边缘衰减的趋势。机械暗角 (mechanical vignetting) 是指光束的边缘部分被遮挡, 从未到达像平面。这可能是由于使用两个透镜或者多个透镜的时候, 光线通过了第一个透镜受到折射, 没有通过第二个透镜从而导致边缘发生衰减。

2.6 颜色 (Colors)

2.6.1 人眼

人眼与相机在结构上类似: 虹膜 (iris) 相当于光圈, 通过改变晶状体的形状对焦, 视网膜 (retina) 相当于胶片或数字传感器。瞳孔 (pupil) 对应针孔或光圈, 视网膜对应感光面。当眼睛正确对焦时, 来自眼外物体的光被成像在视网膜上。

视网膜上有两种感光细胞:

- **视杆细胞 (rods):** 约 7500 万到 1.5 亿个, 不参与颜色视觉, 只提供灰度信息; 灵敏度高, 可以在夜间工作。
- **视锥细胞 (cones):** 约 600 万到 700 万个, 负责颜色视觉, 在中等和高亮度条件下工作。视锥细胞有三种, 光谱灵敏度峰值分别位于短波 (S, 420–440 nm)、中波 (M, 530–540 nm) 和长波 (L, 560–580 nm)。

2.6.2 CIE RGB


由于人眼只有三种视锥细胞, 原则上三个参数就足以描述任何一种人类颜色感觉。反过来, 所有单色光 (单一波长) 都可以用三种适当选择的原色混合得到, 即红 (700.0 nm)、绿 (546.1 nm) 和蓝 (435.8 nm)。

2.7 图像传感 (Image Sensing)

2.7.1 成像管线

从光到数字图像通常经过三个阶段：

1. 相机镜头和机身中的物理光传输 (physical light transport)
2. 传感器芯片上的光子测量与转换 (photon measurement and conversion)
3. 图像信号处理 (image signal processing, ISP) 与图像压缩



2.7.2 快门

焦平面快门 (focal plane shutter) 位于图像传感器或胶片的正前方。多数数码相机使用机械快门与电子快门的组合。快门速度 (即曝光时间) 决定到达传感器的光量，进而决定图像是过曝、欠曝、模糊还是含噪。

2.7.3 传感器

- **CCD:** 电荷在像素之间逐个移动，最终在输出节点统一转换为电压。
- **CMOS:** 在每个像素内部完成电荷到电压的转换，目前是标准方案。

2.7.4 彩色滤镜阵列与去马赛克

为了测量颜色，像素按特定阵列排布，最常见的是 Bayer RGB 图案：每个 2×2 子块包含 2 个绿色、1 个蓝色和 1 个红色滤镜，每个滤镜覆盖一个像素传感器。这样每个像素只能测到一个通道，缺失的其他通道由邻域插值估计，这个过程称为去马赛克（demosaicing）。一般的方法是在图像上进行双线性插值。

绿色滤镜占总数的一半，是因为人眼的亮度敏感函数（luminance sensitivity function）在绿色波段响应最强。

2.7.5 Gamma 校正

人眼对暗部区域的强度差异更加敏感，因此在离散化之前对强度或颜色做非线性变换是有利的，在读取时再撤销这一变换。通常取

$$Y' = Y^{1/\gamma}$$

这样可以给暗部留下更大的区间，最后离散化的时候梯度会更加细密，能够反映出更多细节，简而言之就是能用有限的空间牺牲一点“亮”和“很亮”的区别，保存“黑”和“灰的区别”。同时早期的硬件输出的时候是非线性的，可以抵消一部分硬件问题。在当代，Gamma 校正主要用于图像增强和特征值提取算法。

2.8 本讲小结

- **相机**：针孔模型；世界坐标、相机坐标与图像坐标之间的变换；内参与外参； 3×4 投影矩阵。
- **透镜**：透镜允许大孔径同时保持图像清晰；高斯透镜公式 $\frac{1}{f} = \frac{1}{z} + \frac{1}{z'}$ 。
- **景深**：由光圈控制，小光圈景深大但进光少、噪声大。
- **视场**：由传感器尺寸和像距决定，焦距越短视场越大。
- **畸变**：径向畸变、色差、暗角。
- **颜色与传感**：视杆与视锥细胞、CIE RGB、Bayer 阵列与去马赛克、Gamma 校正。

3 Image Processing

3.1 逐像素处理 Pixel(Point) Processing

3.1.1 基本 P 图操作

Pixel Processing 的基础操作主要有以下几个层面：

- **变暗 (darken)**： $I(x, y) - 128$
- **变亮 (lighten)**： $I(x, y) + 128$

- 降低对比度 (low contrast): $I(x, y)/2$
- 反色 (invert): $255 - I(x, y)$
- 灰度化 (gray): $\text{dot}([0.3, 0.6, 0.1], I(x, y))$, 三个权重依次对应 R、G、B 通道, 绿色权重最大

3.1.2 Histogram Equalization

Pixel Processing 中较复杂的是直方图均衡化方法, 用来调整图像中 RGB 通道的强度。用意在于调整比较复杂的颜色密度分布变换为均匀分布。这个方法的数学原理是将概率分布变换为均匀分布, 寻找一个单调递增的映射函数 T (为了保证是可逆的不丢失信息), 将原有分布复合通过这个映射之后得到均匀分布。

具体的技巧是, 首先把 RGB 的灰度分布曲线画出来 (对每一个颜色通道, 统计每种灰度对应的像素个数, 然后归一化计算概率分布), 得到概率密度函数 pdf, 积分得到 cdf, 将 CDF 的轴拉成 255 对应灰度值范围, 然后将原始灰度数值映射为新的处理过后的灰度值。

$$s_k = (L - 1)CDF(r_k)$$

为什么 CDF 呢? 论证的过程需要依照随机变量变换定理, 变换的规则是变换前后在同一个足够小区间上的必须是一致的 (概率总量守恒)

根据概率论中的随机变量变换定理, 变量变换前后在区间 $[r, r + dr]$ 与 $[s, s + ds]$ 内的概率总量必须守恒:

$$p_s(s)|ds| = p_r(r)|dr|$$

设原始图像的灰度值是一个连续随机变量 $r \in [0, L - 1]$, 其概率密度函数 (PDF) 为 $p_r(r)$ 。我们希望寻找一个单调递增的映射函数 $s = T(r)$, 使得变换后的新灰度变量 s 在 $[0, L - 1]$ 上服从均匀分布, 即:

$$p_s(s) = \frac{1}{L - 1}$$

由于映射函数 $T(r)$ 是单调递增的 (以保证像素灰度相对大小顺序不颠倒, 避免图像反色), 有 $\frac{ds}{dr} > 0$, 因此:

$$p_s(s) = p_r(r) \cdot \frac{dr}{ds}$$

3. 导出映射函数: 累积分布函数 (CDF) 将要求的均匀分布 $p_s(s) = \frac{1}{L-1}$

代入上式:

$$\frac{1}{L - 1} = p_r(r) \cdot \frac{dr}{ds} \implies \frac{ds}{dr} = (L - 1)p_r(r)$$

对微分方程两边关于 r 进行积分:

$$s = T(r) = (L - 1) \int_0^r p_r(w) dw = (L - 1) \cdot F_r(r)$$

其中 $F_r(r)$ 正是原始灰度的累积分布函数 (CDF)。

值得注意的一个拓展: 随机变量变换定理也可以倒过来用, C 语言标准库中, 使用标准随机数在 y 轴上面取值, 反函数映射到 x 轴上, 即可得到关于 x 的均匀随机分布。

3.2 Filtering

3.2.1 线性滤波器

线性滤波器的分类 图像滤波常常用于图像的模糊，锐化，特征提取等算法。线性滤波器就是根据不同的过滤原理实现卷积算子，是一个 3×3 的矩阵 kernel，然后在图像周围补 0，扫描整个图像。

盒式滤波器 (Box Filter) 卷积核为全 1 矩阵除以元素个数，即邻域算术平均，得到低通模糊：

$$K_{\text{box}} = \frac{1}{9} \begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix}$$

高斯滤波器 (Gaussian Filter) 卷积核由二维高斯函数采样并归一化，中心权重大、四周小，同属低通滤波 (Low Pass Filtering)：

$$K_{\text{gauss}} = \frac{1}{16} \begin{bmatrix} 1 & 2 & 1 \\ 2 & 4 & 2 \\ 1 & 2 & 1 \end{bmatrix}$$

锐化滤波器 (Sharpening Filter) 单位冲激核减去均值核，得到高通核：

$$K_{\text{sharp}} = \begin{bmatrix} 0 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 0 \end{bmatrix} - \frac{1}{9} \begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix}$$

等价于在原图上叠加被放大的高频成分：

$$\text{Sharpening: } I + \lambda (I - I_{\text{blur}})$$

其中 I_{blur} 为低通滤波结果， λ 为锐化强度系数。

相关数学知识 算法上来讲，为了实现高效的滤波，在 Separable Filtering 中采用数学技巧降低计算量。本质上在某些核中可以使用线性技巧，将矩阵 Kernel 展开到 $K = vh^T$ 的形式，然后只需要做两个一维乘法。

线性滤波的数学特征主要有以下两个：

- Correlation:

$$g(i, j) = \sum_{k, l} f(i + k, j + l) h(k, l)$$

- Convolution:

$$g(i, j) = \sum_{k, l} f(i - k, j - l) h(k, l)$$

这两个算子都具备线性和平移不变性。

- $h \circ (f_0 + f_1) = h \circ f_0 + h \circ f_1$

- Shift Invariance: $(h \circ g)(i, j) = (h \circ f)(i + h, j + l)$

Filter 和卷积神经网络中的特征提取算法有非常紧密的联系。

3.2.2 非线性滤波器

双边滤波 Gaussian 滤波的主要困难在于只考虑了像素位置的相近性，但是没有考虑像素灰度的差异，会忽略边缘，让重要的信息变模糊。

将 Gaussian 滤波 (Domain Kernel) 和颜色 (Range Kernel) 变化的结合起来，得到 Bilateral Filter 的权重

$$w(i, j, k, l) = \exp\left(-\frac{(i - k)^2 + (j - l)^2}{2\sigma_d^2} - \frac{\|f(i, j) - f(k, l)\|^2}{2\sigma_r^2}\right)$$

将此作为权重，结合 softmax 的归一化操作，得到滤波核

$$g(i, j) = \frac{f(k, l)w(i, j, k, l)}{w(i, j, k, l)} \Rightarrow softmax\left(-\frac{(F_i - F_j)^2}{\sigma}\right)f$$

这种滤波技术常用于美颜磨皮和 ps 技术，多模态学习中的 Kernel 本质上就是可以学习的滤波器。

Joint Bilateral Filter 如果有高清图片作为参考，进行图像滤波的时候可以直接参照正确答案查看颜色的相似性，实现去噪（用没 Flash 的参照给有 Flash 的进行去噪）。这也是神经网络中自注意力的灵感来源。如果自身的颜色细节是不好的，滤波器中的 sigma 参数应当依据无 Flash 的高清图片来确定，得到 joint 滤波。

上图是 No-Flash 图某一行的灰度剖面， σ_d 控制参与平均的空间邻近范围；下图是 Flash 图同一行的剖面， σ_r 由 Flash 图确定颜色相似范围。两者分别对应权重公式中的域核 (Domain Kernel) 与值核 (Range Kernel)。

技术路径分三步：

1. 以 Flash 图为引导图 (guide)，对 No-Flash 图做 Joint Bilateral Filter，得到去噪后的基础层：

$$I_{\text{base}} = \text{JBF}(I_{\text{noflash}} | I_{\text{flash}})$$

2. 对 Flash 图做普通 Bilateral Filter 得到其平滑版本，再相除提取细节层：

$$I_{\text{detail}} = I_{\text{flash}} / \text{BF}(I_{\text{flash}})$$

3. 两者相乘，把 Flash 图的高频细节搬回低噪声的 No-Flash 图上：

$$I_{\text{result}} = I_{\text{base}} \times I_{\text{detail}}$$


想要保持细节，则可以对原图进行滤波，提取高频细节。高频细节为了得到对比度，原图不带闪光灯饱和度低，对比时不宜使用减法提取，应该用除法提取对比度高的图像。

3.3 UpSampling & DownSampling

3.3.1 DownSampling 和防走样

减小图像尺寸如果要通过降采样随机丢弃行列的方法进行实现，有可能出现走样的情况。这是因为采样频率无法反映图形中的高频噪声和高频细节，所以出现了不知所谓的结果。解决的方法是首先进行高斯滤波，将图像变得平滑。

将高斯平滑的方法和 sampling 排列起来，则可以构造出 Gaussian 金字塔，表现这个缩小的过程。



3.3.2 UpSampling

把小的图片放大，会出现非常模糊的情况，为了避免简单使用放大像素的方法，需要进行插值。

插值的数学原理可以用如下公式进行表示，以一元函数插值为例：

设采样点为整数位置 x_k ，已知采样值 $f(x_k)$ ，插值即构造 $g(x)$ 满足 $g(x_k) = f(x_k)$ ，并用于估计采样点之间的函数值。记 x 落在区间 $[x_k, x_{k+1}]$ 内， $t = x - x_k \in [0, 1)$ 。

最近邻插值 (Nearest Neighbor)：取离 x 最近的采样值， $g(x)$ 是阶梯函数

$$g(x) = f(x_k), \quad k = \arg \min_j |x - x_j|$$

线性插值 (Linear)：用相邻两点连直线

$$g(x) = (1 - t) f(x_k) + t f(x_{k+1})$$

Cubic 插值：在每个区间上用三次多项式，由两端函数值与一阶导数连续共四个条件定出系数

$$g(x) \Big|_{[x_k, x_{k+1}]} = a_3(x - x_k)^3 + a_2(x - x_k)^2 + a_1(x - x_k) + a_0$$

$$g(x_k) = f(x_k), \quad g(x_{k+1}) = f(x_{k+1}), \quad g'(x_k^-) = g'(x_k^+), \quad g'(x_{k+1}^-) = g'(x_{k+1}^+)$$

插值的方法有最近邻插值法，线性插值法。最近邻插值就是直接把最近邻居的数值搬过来，形成类似直方图的函数状态；比这个效果稍好的是线性插值，可以至少具有丰富的变化和导数。效果更好的是选取分段的高次函数，比如 Cubic 插值选用三次函数保证一阶连续。

放到图像上采样的插值算法中，双线性插值法是较为常用的，只需要知道周围四个邻居的数值，但是注意，双线性插值是一种非线性插值，结果中有交叉项。如果要追求好的效果，用 Bicubic 插值。

双线性插值 (Bilinear)：用周围四个邻居。记 $u = x - i$, $v = y - j$, $(u, v) \in [0, 1]^2$

$$g(x, y) = (1 - u)(1 - v)f(i, j) + u(1 - v)f(i + 1, j) + (1 - u)v f(i, j + 1) + uv f(i + 1, j + 1)$$

写成矩阵形式，交叉项 uv 出现在展开后的二次项中：

$$g(x, y) = \begin{bmatrix} 1 - u & u \end{bmatrix} \begin{bmatrix} f(i, j) & f(i, j + 1) \\ f(i + 1, j) & f(i + 1, j + 1) \end{bmatrix} \begin{bmatrix} 1 - v \\ v \end{bmatrix}$$

Bicubic 插值：用周围 $4 \times 4 = 16$ 个邻居，两个方向分别套用同一个三次核 W ，可分离地写成

$$g(x, y) = \sum_{m=-1}^2 \sum_{n=-1}^2 f(i + m, j + n) W(u - m) W(v - n)$$

其中 W 为三次卷积核 (a 通常取 -0.5)

$$W(s) = \begin{cases} (a + 2)|s|^3 - (a + 3)|s|^2 + 1, & |s| \leq 1 \\ a|s|^3 - 5a|s|^2 + 8a|s| - 4a, & 1 < |s| < 2 \\ 0, & |s| \geq 2 \end{cases}$$