

计算机视觉 (CV)

Computer Vision

Author: Simson

Date: September 2026

目录

1 计算机视觉简介	1
1.1 计算机视觉概念	1
1.2 计算机视觉的历史脉络 (History of Computer Vision)	1
1.3 计算机视觉概论 (Overview of Computer Vision)	2
1.4 为什么计算机视觉很难 (Why Is Computer Vision Hard?)	2
1.5 计算机视觉的发展波次 (Waves of Computer Vision)	3
1.6 本课程的内容地图 (Course Roadmap)	4

这是计算机视觉（CV）的课堂笔记，笔记参考 PPT 和课程教材，课堂 PPT 为英文，尽量写成中文版

1 计算机视觉简介

1.1 计算机视觉概念

“Make computers see.”

- 输入：光学采样（optical sampling）得到的图像、视频或其他传感器数据。
- 输出：三维场景表示和重建（3D scene representation and reconstruction），以及物体和场景的语义（semantic）。
- 目标：将光学输入转换为语义和结构，回答“图像中有什么、在哪里、是什么，以及接下来可能发生什么”。

1.2 计算机视觉的历史脉络（History of Computer Vision）

计算机视觉并不是一开始就等同于“识别图片中的物体”。它的发展始终围绕一个核心问题展开：如何把二维图像中的光照、颜色和几何信息，转换为对现实世界中物体、场景和行为的可计算理解。

1. **萌芽阶段：从成像到图像处理（Image Formation and Image Processing）**。摄影术、照相机和光学成像理论为计算机视觉提供了数据来源。计算机出现后，研究者首先关注图像的数字化、去噪、增强、边缘检测（edge detection）和分割（segmentation）等问题。这一时期的重点是回答“图像中有哪些可测量的结构”，而不是直接理解图像内容。
2. **早期人工智能阶段：把视觉看作符号推理（Symbolic Reasoning）**。20 世纪 60 年代，计算机视觉逐渐成为人工智能（Artificial Intelligence）的研究方向。早期系统尝试从线条、角点和简单几何图形中恢复物体结构，并将视觉结果交给符号系统进行推理。由于真实图像受到遮挡、噪声、光照变化和视角变化的影响，这类依赖人工规则的方法很难扩展到复杂场景。
3. **理论化阶段：视觉的多层表示（Hierarchical Representation）**。David Marr 提出视觉处理可以分为多个层次：原始图像（primal sketch）、二维半描述（2.5D sketch）以及三维模型（3D model representation）。这一观点强调，视觉不是一次性完成的分类，而是从图像证据逐步构造几何和语义表示（representation）的过程，对后来的三维重建（3D reconstruction）和场景理解（scene understanding）影响深远。
4. **经典特征阶段：从人工特征到统计学习（Hand-crafted Features and Statistical Learning）**。20 世纪 90 年代至 21 世纪初，研究者设计了 SIFT（Scale-Invariant Feature Transform）、HOG（Histogram of Oriented Gradients）等局部或区域特征，并结合支持向量机（Support Vector Machine, SVM）等分类器完成识别任务。随后出现的 Viola-Jones 人脸检测器展示了级联分类器（cascade classifier）在实际应用中的效率。这一阶段的典型流程是“特征提取（feature extraction）+ 分类器（classifier）”。

5. **深度学习阶段：学习视觉表示 (Deep Learning)**。大规模数据集、图形处理器 (Graphics Processing Unit, GPU) 和反向传播 (backpropagation) 共同推动了卷积神经网络 (Convolutional Neural Network, CNN) 的发展。2012 年 AlexNet 在 ImageNet 图像分类任务上的成功，使端到端学习 (end-to-end learning) 成为主流：模型不再完全依赖人工设计特征，而是从数据中联合学习特征和任务目标。目标检测 (object detection)、语义分割 (semantic segmentation) 和实例分割 (instance segmentation) 也因此获得了显著进步。
6. **当前阶段：视觉基础模型 (Vision Foundation Models)**。近年来，视觉 Transformer (Vision Transformer, ViT)、视觉语言模型 (Vision-Language Model, VLM) 和多模态大模型 (multimodal large model) 逐渐成为重要方向。模型可以在大规模图像、文本或视频上进行预训练 (pre-training)，再通过微调 (fine-tuning) 或提示学习 (prompting) 适应下游任务。研究重点也从单一分类任务扩展到图像生成 (image generation)、视频理解 (video understanding)、三维感知 (3D perception) 以及具身智能 (embodied intelligence)。

1.3 计算机视觉概论 (Overview of Computer Vision)

计算机视觉 (Computer Vision, CV) 研究如何使计算机从图像和视频中提取信息，并据此完成测量、识别、预测和决策。常用的概括是 “Make computers see”，但这里的 “see” 并不只是把像素读入内存，而是建立从视觉观测 (visual observation) 到世界模型 (world model) 的联系。

从信息处理的角度看，计算机视觉通常包含以下三个层次：

- **成像与感知 (Imaging and Sensing)**：通过相机 (camera)、深度传感器 (depth sensor)、激光雷达 (LiDAR) 等设备获得图像或视频。需要考虑投影模型 (projection model)、光照 (illumination)、噪声 (noise) 和相机标定 (camera calibration)。
- **表示与理解 (Representation and Understanding)**：将像素转换为边缘、关键点 (keypoint)、纹理 (texture)、物体、姿态 (pose) 和场景结构等表示，并理解物体之间的空间关系。
- **推理与行动 (Inference and Action)**：根据视觉表示完成分类 (classification)、检测 (detection)、跟踪 (tracking)、三维重建 (3D reconstruction)、预测 (prediction) 或控制 (control)。

按照任务目标，计算机视觉问题可以分为几何视觉 (geometric vision)、识别视觉 (recognition)、场景理解 (scene understanding) 和生成视觉 (generative vision) 等方向。几何视觉关注相机、点、线、平面和三维结构之间的关系；识别视觉关注 “图像中有什么”；场景理解进一步回答 “它们在哪里、如何相互作用”；生成视觉则根据图像或文本条件生成新的视觉内容。

计算机视觉与图像处理 (Image Processing)、计算机图形学 (Computer Graphics)、模式识别 (Pattern Recognition) 和机器学习 (Machine Learning) 关系密切，但关注点并不完全相同：图像处理主要改变或恢复图像，图形学主要从模型生成图像，而计算机视觉主要从图像反推出物体、场景和行为。实际系统通常会综合使用这些领域的方法。

1.4 为什么计算机视觉很难 (Why Is Computer Vision Hard?)

计算机看到的首先不是 “猫” “汽车” 或 “街道”，而是一组离散的数字。对于一张 RGB 图像 (RGB image)，每个像素通常由三个颜色通道组成，数值记录的是光在成像平面上的采样结果。计算机需要从

例如 $800 \times 600 \times 3$ 的数值矩阵中恢复物体、材质、空间位置和正在发生的动作，这中间存在明显的语义鸿沟 (semantic gap)。

此外，图像是三维世界在二维平面上的投影 (2D projection of the 3D world)。同一个物体在不同视点、光照和距离下可能产生差异很大的图像；反过来，不同的三维场景也可能投影为相同或非常相似的二维图像。因此，从图像恢复真实场景本质上是一个不适定逆问题 (ill-posed inverse problem)，通常需要引入先验知识 (prior knowledge)、物理假设 (physical assumptions) 或数据驱动的统计规律 (data-driven statistics)。

典型困难包括：

- **视点变化 (viewpoint variation)**：相机位置或观察方向变化会改变物体的外观、可见表面和投影形状。
- **形变 (deformation)**：人体、动物、布料等非刚体 (non-rigid object) 会改变姿态和局部结构。
- **遮挡 (occlusion)**：物体可能被其他物体遮住，系统只能根据不完整的观测推断整体。
- **光照变化 (illumination variation)**：阴影、反射、曝光和光源方向会改变像素值，但不一定改变物体本身。
- **运动 (motion)**：物体和相机都可能运动，导致运动模糊 (motion blur)、目标位移和对应关系变化。
- **局部歧义 (local ambiguity)**：局部纹理或轮廓可能对应多个合理解释，例如错觉图形中的边界并不唯一。
- **类内差异与类间相似 (intra-class variation and inter-class similarity)**：同一类别的物体可能外观差异很大，而不同类别的物体可能具有相似形状或颜色。

因此，视觉系统不仅要完成感知 (perception)，还要完成测量 (measurement) 和推理 (reasoning)。一个系统能够准确分类，并不意味着它已经恢复了可靠的几何结构；同样，能够测量深度的系统，也未必理解场景中的语义关系。

1.5 计算机视觉的发展波次 (Waves of Computer Vision)

按照研究问题和主要技术路线，计算机视觉的发展可以概括为以下几个阶段：

1. **启发式视觉 (1960–1970, Heuristic Vision)**：研究集中于积木世界 (blocks world)、边缘和符号人工智能 (symbolic AI)。Larry Roberts 的 Blocks World 试图从二维线条的拓扑结构推断物体的三维结构；1966 年 MIT Summer Vision Project 则体现了早期对视觉问题复杂度的低估。
2. **低层视觉 (1970–1981, Low-level Vision)**：研究者转向更基础的几何和物理问题，包括阴影形状 (shape from shading)、本征图像 (intrinsic images)、光度立体 (photometric stereo)、双目立体 (stereo)、光流 (optical flow) 和极几何 (epipolar geometry)。这些方法说明，视觉理解必须先处理图像形成和空间对应关系。

3. **神经网络萌芽 (1985–1989, Early Neural Networks)**: 反向传播算法 (backpropagation) 使基于梯度的表示学习成为可能, 早期神经网络开始用于视觉识别; 但受限于数据、算力和网络规模, 神经网络尚未成为主流。
4. **三维几何阶段 (1990–2000, 3D Geometry)**: 稠密立体 (dense stereo)、多视图立体 (multi-view stereo) 和结构光等方法不断发展, 研究重点是从多个图像恢复场景几何。
5. **特征工程阶段 (2000–2010, Feature Engineering)**: SIFT、HOG 等特征描述子 (feature descriptor) 和结构从运动 (Structure from Motion, SfM) 推动了目标识别、图像匹配和大规模照片建模。Kinect 等深度传感器也促进了三维姿态估计和机器人视觉的发展。
6. **深度学习阶段 (2010 至今, Deep Learning)**: ImageNet 提供了大规模标注数据, GPU 提供了训练深层网络的计算能力, AlexNet 在 2012 年 ImageNet 竞赛中的成功由此成为转折点。随后 VGGNet、ResNet、语义分割网络和 Mask R-CNN 等方法将学习式表示扩展到分类、检测、分割和结构化预测。

近年来, 视觉研究进一步从二维识别扩展到三维和跨模态任务。三维深度学习 (3D deep learning) 开始处理体素 (voxel)、点云 (point cloud)、网格 (mesh) 和隐式表示 (implicit representation); NeRF (Neural Radiance Field) 通过学习体渲染函数 (volumetric rendering function) 实现复杂场景的新视角合成 (novel view synthesis); 视觉语言模型 (Vision-Language Model, VLM) 则把图像与文本联系起来, 支持图像描述 (image captioning)、视觉问答 (Visual Question Answering, VQA) 和文本生成图像 (text-to-image generation)。

1.6 本课程的内容地图 (Course Roadmap)

根据计算机视觉的主要问题, 本课程可以分为三个相互联系的模块:

- **图像处理与成像 (Image Processing and Image Formation)**: 研究图像如何产生、如何表示, 以及去噪、增强、滤波、特征提取和图像拼接 (image stitching) 等基本操作。
- **三维视觉 (3D Vision)**: 研究特征与匹配 (features and matching)、从阴影恢复形状、结构从运动、双目和多视图立体重建 (stereo reconstruction) 等问题。
- **计算机视觉深度学习 (Deep Learning for Computer Vision)**: 学习机器学习基础、卷积神经网络、Transformer、表示学习 (representation learning)、目标检测和语义/实例分割。

这三个模块并不是彼此孤立的: 图像形成决定了观测数据的性质, 几何方法提供空间约束, 深度学习则可以从大规模数据中学习更加稳定的表示。一个完整的视觉系统通常要把成像模型、几何推理和数据驱动模型结合起来。