

计算机视觉 (CV)

Computer Vision

Author: Simson

Date: September 2026

目录

1	Introduction to Computer Vision	1
1.1	Computer Vision Concepts	1
1.2	History of Computer Vision	1
1.3	Overview of Computer Vision	2
1.4	Why Is Computer Vision Hard?	2
1.5	Waves of Computer Vision	3
1.6	Course Roadmap	4
2	Image Formation	4
2.1	Camera	5
2.1.1	Why Do We Need a Pinhole	5
2.1.2	Mathematical Pinhole Camera Model	5
2.1.3	Coordinate Systems and Extrinsics	5
2.1.4	Intrinsics	6
2.1.5	Summary of Camera Parameters	6
2.1.6	Properties of Projection	6
2.2	Lens	7
2.2.1	The Pinhole Dilemma	7
2.2.2	Gaussian Lens Formula	7
2.3	Depth of Field	8
2.4	Field of View	8
2.5	Lens Aberrations	8
2.5.1	Radial Distortion	8
2.5.2	Chromatic Aberration	9
2.5.3	Vignetting	9
2.6	Colors	9
2.6.1	The Human Eye	9
2.6.2	CIE RGB	9
2.7	Image Sensing	10
2.7.1	Imaging Pipeline	10
2.7.2	Shutter	10
2.7.3	Sensor	10
2.7.4	Color Filter Array and Demosaicing	11
2.7.5	Gamma Correction	11
2.8	Summary	11

3	Image Processing	11
3.1	Pixel (Point) Processing	11
3.1.1	Basic Pixel Operations	11
3.1.2	Histogram Equalization	12
3.2	Filtering	13
3.2.1	Linear Filters	13
3.2.2	Non-linear Filters	14
3.3	UpSampling & DownSampling	15
3.3.1	DownSampling and Anti-aliasing	15
3.3.2	UpSampling	17
3.3.3	Joint Bilateral Upsampling	18
3.3.4	Image Blending	22
3.4	Image Transformation	23
4	Figure Detection	24
4.1	Edge Detection	24

这是计算机视觉（CV）的课堂笔记，笔记参考 PPT 和课程教材，课堂 PPT 为英文，尽量写成中文版

1 Introduction to Computer Vision

1.1 Computer Vision Concepts

“Make computers see.”

- 输入：光学采样（optical sampling）得到的图像、视频或其他传感器数据。
- 输出：三维场景表示和重建（3D scene representation and reconstruction），以及物体和场景的语义（semantic）。
- 目标：将光学输入转换为语义和结构，回答“图像中有什么、在哪里、是什么，以及接下来可能发生什么”。

1.2 History of Computer Vision

计算机视觉并不是一开始就等同于“识别图片中的物体”。它的发展始终围绕一个核心问题展开：如何把二维图像中的光照、颜色和几何信息，转换为对现实世界中物体、场景和行为的可计算理解。

1. **萌芽阶段：从成像到图像处理（Image Formation and Image Processing）**。摄影术、照相机和光学成像理论为计算机视觉提供了数据来源。计算机出现后，研究者首先关注图像的数字化、去噪、增强、边缘检测（edge detection）和分割（segmentation）等问题。这一时期的重点是回答“图像中有哪些可测量的结构”，而不是直接理解图像内容。
2. **早期人工智能阶段：把视觉看作符号推理（Symbolic Reasoning）**。20 世纪 60 年代，计算机视觉逐渐成为人工智能（Artificial Intelligence）的研究方向。早期系统尝试从线条、角点和简单几何图形中恢复物体结构，并将视觉结果交给符号系统进行推理。由于真实图像受到遮挡、噪声、光照变化和视角变化的影响，这类依赖人工规则的方法很难扩展到复杂场景。
3. **理论化阶段：视觉的多层表示（Hierarchical Representation）**。David Marr 提出视觉处理可以分为多个层次：原始图像（primal sketch）、二维半描述（2.5D sketch）以及三维模型（3D model representation）。这一观点强调，视觉不是一次性完成的分类，而是从图像证据逐步构造几何和语义表示（representation）的过程，对后来的三维重建（3D reconstruction）和场景理解（scene understanding）影响深远。
4. **经典特征阶段：从人工特征到统计学习（Hand-crafted Features and Statistical Learning）**。20 世纪 90 年代至 21 世纪初，研究者设计了 SIFT（Scale-Invariant Feature Transform）、HOG（Histogram of Oriented Gradients）等局部或区域特征，并结合支持向量机（Support Vector Machine, SVM）等分类器完成识别任务。随后出现的 Viola-Jones 人脸检测器展示了级联分类器（cascade classifier）在实际应用中的效率。这一阶段的典型流程是“特征提取（feature extraction）+ 分类器（classifier）”。

5. **深度学习阶段：学习视觉表示 (Deep Learning)**。大规模数据集、图形处理器 (Graphics Processing Unit, GPU) 和反向传播 (backpropagation) 共同推动了卷积神经网络 (Convolutional Neural Network, CNN) 的发展。2012 年 AlexNet 在 ImageNet 图像分类任务上的成功，使端到端学习 (end-to-end learning) 成为主流：模型不再完全依赖人工设计特征，而是从数据中联合学习特征和任务目标。目标检测 (object detection)、语义分割 (semantic segmentation) 和实例分割 (instance segmentation) 也因此获得了显著进步。
6. **当前阶段：视觉基础模型 (Vision Foundation Models)**。近年来，视觉 Transformer (Vision Transformer, ViT)、视觉语言模型 (Vision-Language Model, VLM) 和多模态大模型 (multimodal large model) 逐渐成为重要方向。模型可以在大规模图像、文本或视频上进行预训练 (pre-training)，再通过微调 (fine-tuning) 或提示学习 (prompting) 适应下游任务。研究重点也从单一分类任务扩展到图像生成 (image generation)、视频理解 (video understanding)、三维感知 (3D perception) 以及具身智能 (embodied intelligence)。

1.3 Overview of Computer Vision

计算机视觉 (Computer Vision, CV) 研究如何使计算机从图像和视频中提取信息，并据此完成测量、识别、预测和决策。常用的概括是 “Make computers see”，但这里的 “see” 并不只是把像素读入内存，而是建立从视觉观测 (visual observation) 到世界模型 (world model) 的联系。

从信息处理的角度看，计算机视觉通常包含以下三个层次：

- **成像与感知 (Imaging and Sensing)**：通过相机 (camera)、深度传感器 (depth sensor)、激光雷达 (LiDAR) 等设备获得图像或视频。需要考虑投影模型 (projection model)、光照 (illumination)、噪声 (noise) 和相机标定 (camera calibration)。
- **表示与理解 (Representation and Understanding)**：将像素转换为边缘、关键点 (keypoint)、纹理 (texture)、物体、姿态 (pose) 和场景结构等表示，并理解物体之间的空间关系。
- **推理与行动 (Inference and Action)**：根据视觉表示完成分类 (classification)、检测 (detection)、跟踪 (tracking)、三维重建 (3D reconstruction)、预测 (prediction) 或控制 (control)。

按照任务目标，计算机视觉问题可以分为几何视觉 (geometric vision)、识别视觉 (recognition)、场景理解 (scene understanding) 和生成视觉 (generative vision) 等方向。几何视觉关注相机、点、线、平面和三维结构之间的关系；识别视觉关注 “图像中有什么”；场景理解进一步回答 “它们在哪里、如何相互作用”；生成视觉则根据图像或文本条件生成新的视觉内容。

计算机视觉与图像处理 (Image Processing)、计算机图形学 (Computer Graphics)、模式识别 (Pattern Recognition) 和机器学习 (Machine Learning) 关系密切，但关注点并不完全相同：图像处理主要改变或恢复图像，图形学主要从模型生成图像，而计算机视觉主要从图像反推出物体、场景和行为。实际系统通常会综合使用这些领域的方法。

1.4 Why Is Computer Vision Hard?

计算机看到的首先不是 “猫” “汽车” 或 “街道”，而是一组离散的数字。对于一张 RGB 图像 (RGB image)，每个像素通常由三个颜色通道组成，数值记录的是光在成像平面上的采样结果。计算机需要从

例如 $800 \times 600 \times 3$ 的数值矩阵中恢复物体、材质、空间位置和正在发生的动作，这中间存在明显的语义鸿沟 (semantic gap)。

此外，图像是三维世界在二维平面上的投影 (2D projection of the 3D world)。同一个物体在不同视点、光照和距离下可能产生差异很大的图像；反过来，不同的三维场景也可能投影为相同或非常相似的二维图像。因此，从图像恢复真实场景本质上是一个不适定逆问题 (ill-posed inverse problem)，通常需要引入先验知识 (prior knowledge)、物理假设 (physical assumptions) 或数据驱动的统计规律 (data-driven statistics)。

典型困难包括：

- **视点变化 (viewpoint variation)**：相机位置或观察方向变化会改变物体的外观、可见表面和投影形状。
- **形变 (deformation)**：人体、动物、布料等非刚体 (non-rigid object) 会改变姿态和局部结构。
- **遮挡 (occlusion)**：物体可能被其他物体遮住，系统只能根据不完整的观测推断整体。
- **光照变化 (illumination variation)**：阴影、反射、曝光和光源方向会改变像素值，但不一定改变物体本身。
- **运动 (motion)**：物体和相机都可能运动，导致运动模糊 (motion blur)、目标位移和对应关系变化。
- **局部歧义 (local ambiguity)**：局部纹理或轮廓可能对应多个合理解释，例如错觉图形中的边界并不唯一。
- **类内差异与类间相似 (intra-class variation and inter-class similarity)**：同一类别的物体可能外观差异很大，而不同类别的物体可能具有相似形状或颜色。

因此，视觉系统不仅要完成感知 (perception)，还要完成测量 (measurement) 和推理 (reasoning)。一个系统能够准确分类，并不意味着它已经恢复了可靠的几何结构；同样，能够测量深度的系统，也未必理解场景中的语义关系。

1.5 Waves of Computer Vision

按照研究问题和主要技术路线，计算机视觉的发展可以概括为以下几个阶段：

1. **启发式视觉 (1960–1970, Heuristic Vision)**：研究集中于积木世界 (blocks world)、边缘和符号人工智能 (symbolic AI)。Larry Roberts 的 Blocks World 试图从二维线条的拓扑结构推断物体的三维结构；1966 年 MIT Summer Vision Project 则体现了早期对视觉问题复杂度的低估。
2. **低层视觉 (1970–1981, Low-level Vision)**：研究者转向更基础的几何和物理问题，包括阴影形状 (shape from shading)、本征图像 (intrinsic images)、光度立体 (photometric stereo)、双目立体 (stereo)、光流 (optical flow) 和极几何 (epipolar geometry)。这些方法说明，视觉理解必须先处理图像形成和空间对应关系。

3. **神经网络萌芽 (1985–1989, Early Neural Networks)**: 反向传播算法 (backpropagation) 使基于梯度的表示学习成为可能, 早期神经网络开始用于视觉识别; 但受限于数据、算力和网络规模, 神经网络尚未成为主流。
4. **三维几何阶段 (1990–2000, 3D Geometry)**: 稠密立体 (dense stereo)、多视图立体 (multi-view stereo) 和结构光等方法不断发展, 研究重点是从多个图像恢复场景几何。
5. **特征工程阶段 (2000–2010, Feature Engineering)**: SIFT、HOG 等特征描述子 (feature descriptor) 和结构从运动 (Structure from Motion, SfM) 推动了目标识别、图像匹配和大规模照片建模。Kinect 等深度传感器也促进了三维姿态估计和机器人视觉的发展。
6. **深度学习阶段 (2010 至今, Deep Learning)**: ImageNet 提供了大规模标注数据, GPU 提供了训练深层网络的计算能力, AlexNet 在 2012 年 ImageNet 竞赛中的成功由此成为转折点。随后 VGGNet、ResNet、语义分割网络和 Mask R-CNN 等方法将学习式表示扩展到分类、检测、分割和结构化预测。

近年来, 视觉研究进一步从二维识别扩展到三维和跨模态任务。三维深度学习 (3D deep learning) 开始处理体素 (voxel)、点云 (point cloud)、网格 (mesh) 和隐式表示 (implicit representation); NeRF (Neural Radiance Field) 通过学习体渲染函数 (volumetric rendering function) 实现复杂场景的新视角合成 (novel view synthesis); 视觉语言模型 (Vision-Language Model, VLM) 则把图像与文本联系起来, 支持图像描述 (image captioning)、视觉问答 (Visual Question Answering, VQA) 和文本生成图像 (text-to-image generation)。

1.6 Course Roadmap

根据计算机视觉的主要问题, 本课程可以分为三个相互联系的模块:

- **图像处理与成像 (Image Processing and Image Formation)**: 研究图像如何产生、如何表示, 以及去噪、增强、滤波、特征提取和图像拼接 (image stitching) 等基本操作。
- **三维视觉 (3D Vision)**: 研究特征与匹配 (features and matching)、从阴影恢复形状、结构从运动、双目和多视图立体重建 (stereo reconstruction) 等问题。
- **计算机视觉深度学习 (Deep Learning for Computer Vision)**: 学习机器学习基础、卷积神经网络、Transformer、表示学习 (representation learning)、目标检测和语义/实例分割。

这三个模块并不是彼此孤立的: 图像形成决定了观测数据的性质, 几何方法提供空间约束, 深度学习则可以从大规模数据中学习更加稳定的表示。一个完整的视觉系统通常需要把成像模型、几何推理和数据驱动模型结合起来。

2 Image Formation

本讲讨论图像是如何形成的: 先由最简单的针孔模型建立相机的数学描述, 再引入透镜, 最后讨论景深、视场、镜头像差、颜色和图像传感。

2.1 Camera

2.1.1 Why Do We Need a Pinhole

如果把数字传感器（CCD 或 CMOS）直接对着真实场景，每个传感器像素都会接收到来自场景中几乎所有点的光线，各种方向的光被平均在一起，得到的图像完全模糊。问题在于没有对光线的方向施加任何限制。

针孔相机（pinhole camera）在传感器前放置一块不透光的挡板（barrier/diaphragm），上面开一个针孔（pinhole/aperture）。绝大多数光线被挡住，只有一条光线能穿过针孔到达传感器，于是场景中的每个点只对应传感器上的一个像素，图像变得清晰。

小孔成像在中国古代已有记载。《墨经·经下》：“景到，在午有端与景长，说在端。”《经说下》：“景。光之人，煦若射，下者之人也高；高者之人也下。足蔽下光，故成景于上；首蔽上光，故成景于下。在远近有端，与于光，故景库内也。”其中已经指出倒像（“景到”）的成因是光沿直线传播并被小孔限制。

日常环境中也常出现偶然的针孔相机（accidental pinhole camera）：树叶缝隙、窗帘孔洞等会投出成像，这些成像常常不被注意或被误认为阴影。Torralba 和 Freeman 在 *Accidental Pinhole and Pinspeck Cameras* (CVPR 2012) 中对此做了系统研究。

2.1.2 Mathematical Pinhole Camera Model

物理上像平面位于针孔之后，成倒像；为了建模方便，通常把像平面平移到针孔之前，此时成的是正像，几何关系不变。设相机坐标系中物点坐标为 (x, y, z) ，像平面上的像点坐标为 (x', y') ，针孔到像平面的距离（焦距）为 f ，由相似三角形得

$$\frac{x'}{f} = \frac{x}{z}, \quad \frac{y'}{f} = \frac{y}{z}$$

即

$$x' = f \frac{x}{z}, \quad y' = f \frac{y}{z}$$

注意这里出现了除以 z 的运算，因此投影并不是线性变换，这一点后面还会展开。

2.1.3 Coordinate Systems and Extrinsics

成像过程涉及三个坐标系：世界坐标系（world coordinates）、相机坐标系（camera coordinates）和图像坐标系（image coordinates）。

外参（extrinsic parameters）描述如何把世界坐标中的点 (x, y, z) 变换到相机坐标系，包含两部分：

- 相机或物体的位置 → 平移（translation），3 个自由度
- 相机或物体的朝向 → 旋转（rotation），3 个自由度

合起来是刚体变换（rigid transformation），共 6 个自由度。

用齐次坐标（homogeneous coordinates）可以把平移和旋转统一写成矩阵乘法。齐次坐标把一个点表示为多一维的向量，并通过最后一维归一化：

$$\mathbf{x} = (x, y, z, w) \cong \left(\frac{x}{w}, \frac{y}{w}, \frac{z}{w}, 1 \right)$$

于是平移、旋转和刚体变换分别写成

$$T = \begin{bmatrix} I_{3 \times 3} & t_{3 \times 1} \\ 0 & 1 \end{bmatrix}, \quad R = \begin{bmatrix} R_{3 \times 3} & 0 \\ 0 & 1 \end{bmatrix}, \quad M = \begin{bmatrix} R_{3 \times 3} & t_{3 \times 1} \\ 0 & 1 \end{bmatrix}$$

其中 I 为单位矩阵, t 为平移向量。下标只用于标注各块的形状, 实际书写时可以省略。

2.1.4 Intrinsics

内参 (intrinsic parameters) 描述如何把相机坐标系中的点 (x, y, z) 投影到图像平面, 本质上是图像平面内的缩放加平移, 用二维齐次坐标表示为

$$\begin{bmatrix} u \\ v \\ w \end{bmatrix} = K \begin{bmatrix} x \\ y \\ z \end{bmatrix}, \quad K = \begin{bmatrix} \alpha f & s & c_x \\ 0 & f & c_y \\ 0 & 0 & 1 \end{bmatrix}$$

矩阵最后一行的 $[0 \ 0 \ 1]$ 对应透视投影 (projective); 若换成 $[0 \ 0 \ 0 \ 1]$, 得到的是正交投影 (orthographic)。 K 中各参数的含义是:

- f : 焦距
- α : 纵横比 (aspect ratio), 像素为正方形时等于 1
- s : 倾斜 (skew), 只有当像素是平行四边形时才非零
- (c_x, c_y) : 主点 (principal point), 当光轴与图像中心相交时等于 $(w/2, h/2)$

2.1.5 Summary of Camera Parameters

外参 (旋转 R 与平移 t) 和内参 K 合起来给出 3×4 的投影矩阵:

$$P = K \begin{bmatrix} R_{3 \times 3} & t_{3 \times 1} \end{bmatrix}$$

它把世界坐标中的三维点直接映射为图像平面上的二维点。

2.1.6 Properties of Projection

投影不是线性变换 (因为要除以 z), 但仍保留若干结构性质:

- 点投影为点, 直线投影为直线
- 角度不被保持
- 每一组平行线交于同一个点, 称为灭点 (vanishing point)

以“直线投影为直线”为例,设三维直线由一点 $\mathbf{X}_0 = (X_0, Y_0, Z_0, 1)^T$ 和方向向量 $\mathbf{D} = (D_1, D_2, D_3)^T$ 参数化:

$$\mathbf{X}_t = \begin{bmatrix} X_0 + tD_1 \\ Y_0 + tD_2 \\ Z_0 + tD_3 \\ 1 \end{bmatrix} \cong \begin{bmatrix} X_0/t + D_1 \\ Y_0/t + D_2 \\ Z_0/t + D_3 \\ 1/t \end{bmatrix} \xrightarrow{t \rightarrow \infty} \begin{bmatrix} D_1 \\ D_2 \\ D_3 \\ 0 \end{bmatrix} = \mathbf{X}_\infty$$

把直线的参数方程代入投影矩阵并消去参数 t , 得到的是图像平面上的一条直线。

$\mathbf{X}_\infty$ 称为无穷远点 (point at infinity), 它的投影就是灭点:

$$\mathbf{v} \cong P\mathbf{X}_\infty$$

所有方向相同的直线共享同一个灭点。当灭点位于无穷远时, 对应的一组直线在图像中仍然平行。相机相对于场景的朝向决定了有几个方向的平行线在图像中汇聚, 这也就是一点透视 (one point perspective)、两点透视 (two point perspective) 和三点透视的区别。

2.2 Lens

2.2.1 The Pinhole Dilemma

- 针孔太小: 进入的光很少, 图像很暗, 需要很长的曝光时间; 同时衍射 (diffraction) 开始起作用, 同样会使图像模糊。
- 针孔太大: 进光量增加, 图像变亮, 但每个像素会平均来自多个方向的光线, 图像失去锐度。

因此针孔相机的成像总是偏暗而且偏慢: 对于场景中的某个点, 单位时间内只有极少数光线能够到达像平面, 而针孔的大小又必须很小才能保证清晰。

2.2.2 Gaussian Lens Formula

透镜的作用是在尽可能保持理想针孔相机抽象的同时捕获更多的光, 也就是允许使用大孔径并且仍然得到清晰的图像。

把针孔换成透镜后, 设物距为 z 、像距为 z' 、焦距为 f 。由相似三角形 $x/z = x'/z'$ 得 $x/x' = z/z'$, 再结合 $(x' + x)/f = x'/z$, 有

$$\frac{1}{f} = \frac{x' + x}{x'z} = \frac{1}{z} + \frac{x}{x'z} = \frac{1}{z} + \frac{1}{z'}$$


即高斯透镜公式 (Gaussian lens equation):

$$\frac{1}{f} = \frac{1}{z} + \frac{1}{z'}$$

当物体位于无穷远 ($z = \infty$) 时, $z' = f$, 即像距等于焦距, 这就是对无穷远对焦的情形。(在实际情况下, 由于真实相机的焦距通常非常小对于远处的物体和风景可以将物距当作无穷远进行考虑)

2.3 Depth of Field

在焦距和像平面固定之后，只有一个特定距离上的物体是“对焦”的，其他距离的点会投影成图像平面上的一个弥散圆（circle of confusion）。



景深（depth of field, DOF）定义为场景中看起来足够清晰（acceptably sharp）的最近物体与最远物体之间的距离。

控制景深的主要手段是光圈（aperture）大小：

- 光圈越小，景深越大
- 但小光圈减少进光量，需要增加曝光时间，图像噪声更大

实际拍摄中的取舍是：大光圈适合拍摄孤立主体，例如夜景或人像；小光圈提供更大的景深，适合风景、流水等题材。

2.4 Field of View

视场（field of view, FoV）是相机所观测到的世界的角度范围。设传感器尺寸为 d ，像距为 z' ，视场角为 α ，则

$$\tan \frac{\alpha}{2} = \frac{d/2}{z'}$$

其中 $z' = (1 + m)F$ ， m 为放大率；对无穷远对焦时 $z' = F$ 。焦距越短，视场越大（广角）；焦距越长，视场越小（长焦）。感受整体的风景效果，应当采用短焦镜头增大视角。拍摄远处的东西，采用长焦镜头。

2.5 Lens Aberrations

2.5.1 Radial Distortion

径向畸变（radial distortion）由透镜不完美引起，在广角镜头中尤其明显，越靠近图像边缘越显著，表现为图像内容被压缩。负径向畸变指的是图像背离径向方向发生变形，这由于使用了超广角镜头，导致图片呈现木桶式的向外膨胀现象；正径向畸变反之，是向内陷入的现象。

建模时不再直接使用标准投影矩阵，而是分三步进行：

1. 投影到“归一化”图像坐标 (normalized image coordinates): $x_n = x/z$, $y_n = y/z$

2. 施加径向畸变:

$$x_d = x_n (1 + k_1 r^2 + k_2 r^4), \quad y_d = y_n (1 + k_1 r^2 + k_2 r^4)$$

其中 $r^2 = x_n^2 + y_n^2$, k_1, k_2 为畸变系数

3. 施加焦距并平移到图像中心: $u = f x_d + c_x$, $v = f y_d + c_y$

OpenCV 提供了标定和去畸变的实现。畸变对不同题材的影响不同: 广角适合强调透视, 标准镜头接近人眼观感, 长焦则压缩空间。

2.5.2 Chromatic Aberration

玻璃的折射率随波长略有变化, 因此简单透镜存在色差 (chromatic aberration): 不同颜色的光聚焦在略微不同的距离上, 表现为模糊和颜色偏移。为了减弱色差和其他像差, 多数摄影镜头采用由不同玻璃元件 (以及不同镀膜) 组成的复合透镜 (compound lens)。

2.5.3 Vignetting

湮灭, 也叫暗角 (vignetting), 指亮度向图像边缘衰减的趋势。机械暗角 (mechanical vignetting) 是指光束的边缘部分被遮挡, 从未到达像平面。这可能是由于使用两个透镜或者多个透镜的时候, 光线通过了第一个透镜受到折射, 没有通过第二个透镜从而导致边缘发生衰减。

2.6 Colors

2.6.1 The Human Eye

人眼与相机在结构上类似: 虹膜 (iris) 相当于光圈, 通过改变晶状体的形状对焦, 视网膜 (retina) 相当于胶片或数字传感器。瞳孔 (pupil) 对应针孔或光圈, 视网膜对应感光面。当眼睛正确对焦时, 来自眼外物体的光被成像在视网膜上。

视网膜上有两种感光细胞:

- **视杆细胞 (rods):** 约 7500 万到 1.5 亿个, 不参与颜色视觉, 只提供灰度信息; 灵敏度高, 可以在夜间工作。
- **视锥细胞 (cones):** 约 600 万到 700 万个, 负责颜色视觉, 在中等和高亮度条件下工作。视锥细胞有三种, 光谱灵敏度峰值分别位于短波 (S, 420–440 nm)、中波 (M, 530–540 nm) 和长波 (L, 560–580 nm)。

2.6.2 CIE RGB


由于人眼只有三种视锥细胞, 原则上三个参数就足以描述任何一种人类颜色感觉。反过来, 所有单色光 (单一波长) 都可以用三种适当选择的原色混合得到, 即红 (700.0 nm)、绿 (546.1 nm) 和蓝 (435.8 nm)。

2.7 Image Sensing

2.7.1 Imaging Pipeline

从光到数字图像通常经过三个阶段：

1. 相机镜头和机身中的物理光传输（physical light transport）
2. 传感器芯片上的光子测量与转换（photon measurement and conversion）
3. 图像信号处理（image signal processing, ISP）与图像压缩



2.7.2 Shutter

焦平面快门（focal plane shutter）位于图像传感器或胶片的正前方。多数数码相机使用机械快门与电子快门的组合。快门速度（即曝光时间）决定到达传感器的光量，进而决定图像是过曝、欠曝、模糊还是含噪。

2.7.3 Sensor

- **CCD**：电荷在像素之间逐个移动，最终在输出节点统一转换为电压。
- **CMOS**：在每个像素内部完成电荷到电压的转换，目前是标准方案。

2.7.4 Color Filter Array and Demosaicing

为了测量颜色，像素按特定阵列排布，最常见的是 Bayer RGB 图案：每个 2×2 子块包含 2 个绿色、1 个蓝色和 1 个红色滤镜，每个滤镜覆盖一个像素传感器。这样每个像素只能测到一个通道，缺失的其他通道由邻域插值估计，这个过程称为去马赛克（demosaicing）。一般的方法是在图像上进行双线性插值。

绿色滤镜占总数的一半，是因为人眼的亮度敏感函数（luminance sensitivity function）在绿色波段响应最强。

2.7.5 Gamma Correction

人眼对暗部区域的强度差异更加敏感，因此在离散化之前对强度或颜色做非线性变换是有利的，在读取时再撤销这一变换。通常取

$$Y' = Y^{1/\gamma}$$

这样可以给暗部留下更大的区间，最后离散化的时候梯度会更加细密，能够反映出更多细节，简而言之就是能用有限的空间牺牲一点“亮”和“很亮”的区别，保存“黑”和“灰的区别”。同时早期的硬件输出的时候是非线性的，可以抵消一部分硬件问题。在当代，Gamma 校正主要用于图像增强和特征值提取算法。

2.8 Summary

- **相机：**针孔模型；世界坐标、相机坐标与图像坐标之间的变换；内参与外参； 3×4 投影矩阵。
- **透镜：**透镜允许大孔径同时保持图像清晰；高斯透镜公式 $\frac{1}{f} = \frac{1}{z} + \frac{1}{z'}$ 。
- **景深：**由光圈控制，小光圈景深大但进光少、噪声大。
- **视场：**由传感器尺寸和像距决定，焦距越短视场越大。
- **畸变：**径向畸变、色差、暗角。
- **颜色与传感：**视杆与视锥细胞、CIE RGB、Bayer 阵列与去马赛克、Gamma 校正。

3 Image Processing

3.1 Pixel (Point) Processing

3.1.1 Basic Pixel Operations

Pixel Processing 的基础操作主要有以下几个层面：

- **变暗 (darken)：** $I(x, y) - 128$
- **变亮 (lighten)：** $I(x, y) + 128$

- 降低对比度 (low contrast): $I(x, y)/2$
- 反色 (invert): $255 - I(x, y)$
- 灰度化 (gray): $\text{dot}([0.3, 0.6, 0.1], I(x, y))$, 三个权重依次对应 R、G、B 通道, 绿色权重最大

3.1.2 Histogram Equalization

Pixel Processing 中较复杂的是直方图均衡化方法, 用来调整图像中 RGB 通道的强度。用意在于调整比较复杂的颜色密度分布变换为均匀分布。这个方法的数学原理是将概率分布变换为均匀分布, 寻找一个单调递增的映射函数 T (为了保证是可逆的不丢失信息), 将原有分布复合通过这个映射之后得到均匀分布。

具体的技巧是, 首先把 RGB 的灰度分布曲线画出来 (对每一个颜色通道, 统计每种灰度对应的像素个数, 然后归一化计算概率分布), 得到概率密度函数 pdf, 积分得到 cdf, 将 CDF 的轴拉成 255 对应灰度值范围, 然后将原始灰度数值映射为新的处理过后的灰度值。

$$s_k = (L - 1)CDF(r_k)$$

为什么 CDF 呢? 论证的过程需要依照随机变量变换定理, 变换的规则是变换前后在同一个足够小区间上的必须是一致的 (概率总量守恒)

根据概率论中的随机变量变换定理, 变量变换前后在区间 $[r, r + dr]$ 与 $[s, s + ds]$ 内的概率总量必须守恒:

$$p_s(s)|ds| = p_r(r)|dr|$$

设原始图像的灰度值是一个连续随机变量 $r \in [0, L - 1]$, 其概率密度函数 (PDF) 为 $p_r(r)$ 。我们希望寻找一个单调递增的映射函数 $s = T(r)$, 使得变换后的新灰度变量 s 在 $[0, L - 1]$ 上服从均匀分布, 即:

$$p_s(s) = \frac{1}{L - 1}$$

由于映射函数 $T(r)$ 是单调递增的 (以保证像素灰度相对大小顺序不颠倒, 避免图像反色), 有 $\frac{ds}{dr} > 0$, 因此:

$$p_s(s) = p_r(r) \cdot \frac{dr}{ds}$$

3. 导出映射函数: 累积分布函数 (CDF) 将要求的均匀分布 $p_s(s) = \frac{1}{L-1}$

代入上式:

$$\frac{1}{L - 1} = p_r(r) \cdot \frac{dr}{ds} \implies \frac{ds}{dr} = (L - 1)p_r(r)$$

对微分方程两边关于 r 进行积分:

$$s = T(r) = (L - 1) \int_0^r p_r(w) dw = (L - 1) \cdot F_r(r)$$

其中 $F_r(r)$ 正是原始灰度的累积分布函数 (CDF)。

值得注意的一个拓展: 随机变量变换定理也可以倒过来用, C 语言标准库中, 使用标准随机数在 y 轴上面取值, 反函数映射到 x 轴上, 即可得到关于 x 的均匀随机分布。

3.2 Filtering

3.2.1 Linear Filters

Classification of Linear Filters 图像滤波常常用于图像的模糊，锐化，特征提取等算法。线性滤波器就是根据不同的过滤原理实现卷积算子，是一个 3×3 的矩阵 kernel，然后在图像周围补 0，扫描整个图像。

Box Filter 卷积核为全 1 矩阵除以元素个数，即邻域算术平均，得到低通模糊：

$$K_{\text{box}} = \frac{1}{9} \begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix}$$

Gaussian Filter 卷积核由二维高斯函数采样并归一化，中心权重大、四周小，同属低通滤波（Low Pass Filtering）：

$$K_{\text{gauss}} = \frac{1}{16} \begin{bmatrix} 1 & 2 & 1 \\ 2 & 4 & 2 \\ 1 & 2 & 1 \end{bmatrix}$$

Sharpening Filter 单位冲激核减去均值核，得到高通核：

$$K_{\text{sharp}} = \begin{bmatrix} 0 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 0 \end{bmatrix} - \frac{1}{9} \begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix}$$

等价于在原图上叠加被放大的高频成分：

$$\text{Sharpening: } I + \lambda(I - I_{\text{blur}})$$

其中 I_{blur} 为低通滤波结果， λ 为锐化强度系数。

Mathematical Background 算法上来讲，为了实现高效的滤波，在 Separable Filtering 中采用数学技巧降低计算量。本质上在某些核中可以使用线性技巧，将矩阵 Kernel 展开到 $K = vh^T$ 的形式，然后只需要做两个一维乘法。

线性滤波的数学特征主要有以下两个：

- Correlation:

$$g(i, j) = \sum_{k, l} f(i + k, j + l)h(k, l)$$

- Convolution:

$$g(i, j) = \sum_{k, l} f(i - k, j - l)h(k, l)$$

这两个算子都具备线性和平移不变性。

- $h \circ (f_0 + f_1) = h \circ f_0 + h \circ f_1$
- Shift Invarience: $(h \circ g)(i, j) = (h \circ f)(i + h, j + l)$

Filter 和卷积神经网络中的特征提取算法有非常紧密的联系。

3.2.2 Non-linear Filters

Bilateral Filter Gaussian 滤波的主要困难在于只考虑了像素位置的相近性，但是没有考虑像素灰度的差异，会忽略边缘，让重要的信息变模糊。

将 Gaussian 滤波 (Domain Kernel) 和颜色 (Range Kernel) 变化的结合起来，得到 Bilateral Filter 的权重

$$w(i, j, k, l) = \exp\left(-\frac{(i - k)^2 + (j - l)^2}{2\sigma_d^2} - \frac{\|f(i, j) - f(k, l)\|^2}{2\sigma_r^2}\right)$$

将此作为权重，结合 softmax 的归一化操作，得到滤波核

$$g(i, j) = \frac{f(k, l)w(i, j, k, l)}{w(i, j, k, l)} \Rightarrow softmax\left(-\frac{(F_i - F_j)^2}{\sigma}f\right)$$

这种滤波技术常用于美颜磨皮和 ps 技术，多模态学习中的 Kernel 本质上就是可以学习的滤波器。

Joint Bilateral Filter 如果有高清图片作为参考，进行图像滤波的时候可以直接参照正确答案查看颜色的相似性，实现去噪（用没 Flash 的参照给有 Flash 的进行去噪）。这也是神经网络中自注意力的灵感来源。如果自身的颜色细节是不好的，滤波器中的 sigma 参数应当依据无 Flash 的高清图片来确定，得到 joint 滤波。

上图是 No-Flash 图某一行的灰度剖面， σ_d 控制参与平均的空间邻近范围；下图是 Flash 图同一行的剖面， σ_r 由 Flash 图确定颜色相似范围。两者分别对应权重公式中的域核 (Domain Kernel) 与值核 (Range Kernel)。

技术路径分三步：

1. 以 Flash 图为引导图 (guide)，对 No-Flash 图做 Joint Bilateral Filter，得到去噪后的基础层：

$$I_{\text{base}} = \text{JBF}(I_{\text{noflash}} | I_{\text{flash}})$$

2. 对 Flash 图做普通 Bilateral Filter 得到其平滑版本，再相除提取细节层：

$$I_{\text{detail}} = I_{\text{flash}} / \text{BF}(I_{\text{flash}})$$

3. 两者相乘，把 Flash 图的高频细节搬回低噪声的 No-Flash 图上：

$$I_{\text{result}} = I_{\text{base}} \times I_{\text{detail}}$$

想要保持细节，则可以对原图进行滤波，提取高频细节。高频细节为了得到对比度，原图不带闪光灯饱和度低，对比时不宜使用减法提取，应该用除法提取对比度高的图像。

3.3 UpSampling & DownSampling

3.3.1 DownSampling and Anti-aliasing

减小图像尺寸如果要通过降采样随机丢弃行列的方法进行实现，有可能出现走样的情况。这是因为采样频率无法反映图形中的高频噪声和高频细节，所以出现了不知所谓的结果。解决的方法是首先进行高斯滤波，将图像变得平滑。

将高斯平滑的方法和 sampling 排列起来，则可以构造出 Gaussian 金字塔，表现这个缩小的过程。




图 1: Gaussian 金字塔: 每一级先做高斯模糊 (Blur) 再降采样 (Subsample), 逐级得到尺寸减半的图像

Laplacian Pyramid 高斯金字塔每一级只保留低通信息，细节在模糊与降采样中被丢掉了。把相邻两级相减，就能把这些细节显式地取出来：

$$L_i = G_i - \text{upsample}(G_{i+1}), \quad G_i = L_i + \text{upsample}(G_{i+1})$$

其中 $\text{upsample}(\cdot)$ 就是下一小节的插值放大（对应图中的“ $\times 2$ ”节点），相减对应图中的圆圈；最粗的一级没有更粗的层可减，直接取 $L_4 = G_4$ 。

右式说明这个表示是**可逆**的：从 L_4 逐层加回去即可无损重建原图，而单用高斯金字塔则只有低通信息。 $\{L_1, \dots, L_4\}$ 的优势可以顺着图看：

- **分辨率分层**： L_1 是最细的纹理与边缘， L_2 、 L_3 依次是更粗的结构， L_4 是那张最小的图，基本只剩低频。每一层对应一个明确的尺度，可以单独处理。
- **分频带 (band-pass)**： 每层只保留相邻两个尺度之间那一带频率。图中 L_1 、 L_2 呈灰底加少量纹理，说明带通系数大多接近 0、非常稀疏，量化、阈值化和压缩都很划算（拉普拉斯金字塔是早期图像压缩的方案，也是小波变换的前身）。




图 2: Laplacian 金字塔: L_i 是 G_i 减去放大后的 G_{i+1} 所得的残差

- **冗余很小**: 每层样本数按 $1/4$ 递减, 加总约为原图的 $4/3$, 只多花三分之一的空间就换来多尺度表示。
- **便于分尺度编辑**: 亮度和细节被拆到了不同层, 做色调映射、细节增强时可以只动某一层而不波及其他尺度; 做图像融合时在不同层分别加权, 还能避免拼接处的接缝。

图中每个“ $\times 2$ ”节点都要靠插值把粗层放大来预测细层, 预测得越准, 残差层就越稀疏、越好压缩——这正是保边上采样 (如 JBU) 在实践中的价值。Laplacian 金字塔因为逐级分频率保存信息, 可以在数据传输中实现逐渐叠加, 从模糊到清晰的效果。同时可以作为一种可以恢复原状的图像压缩技术。

下面总结并阐述了 Laplacian 金字塔的构造过程和处理流程:

Summary of Laplacian Pyramid




图 3: Laplacian 金字塔的分解 (左) 与重建 (右) 流程

左半是分解：每级先用高斯滤波 H_0 平滑、再降采样 $\downarrow 2$ 得到粗层，粗层经上采样 $\uparrow 2$ 与插值 I 回到细层网格后，在求和点与原图相减 $(-)$ 得到该级的细节残差，再进入下一级，如此逐级级联；右半是重建：各层数据经 Q 后逐级上采样、插值并相加，最终得到输出 O 。黄色块是各层的图像数据，蓝色块是可逆的滤波算子。

Mathematics of the Laplacian Pyramid 根据构造流程，首先进行 Gauss 滤波，然后将不同程度的 Gauss 滤波进行做差和求微分过程：

$$G(x, y, \sigma) = \frac{1}{2\pi\sigma} e^{-\frac{x^2+y^2}{2\sigma^2}} \quad \nabla^2 f = \frac{\partial^2 f}{\partial x^2} + \frac{\partial^2 f}{\partial y^2}$$

根据上述函数，将 laplace 算子作用在上面。

$$\nabla^2 G(x, y, \sigma) = \left(\frac{x^2 + y^2}{\sigma^4} - \frac{2}{\sigma^2} \right) G(x, y, \sigma) = \frac{\partial G}{\partial \sigma} \frac{1}{\sigma}$$

得到了 Gauss 函数非常重要的数学关系，使用展开式进行离散化。

$$\sigma \nabla^2 G(x, y, \sigma) = \frac{\partial G}{\partial \sigma} \simeq \left(\frac{G(x, y, h\sigma) - G(x, y, \sigma)}{h\sigma - \sigma} \right)$$

化简得到：

$$G(x, y, k\sigma) - G(x, y, \sigma) \simeq (k - 1)\sigma^2 \nabla^2 G$$

这就是 laplace 金字塔的数学模型。

3.3.2 UpSampling

把小的图片放大，会出现非常模糊的情况，为了避免简单使用放大像素的方法，需要进行插值。

插值的数学原理可以用如下公式进行表示，以一元函数插值为例：

设采样点为整数位置 x_k ，已知采样值 $f(x_k)$ ，插值即构造 $g(x)$ 满足 $g(x_k) = f(x_k)$ ，并用于估计采样点之间的函数值。记 x 落在区间 $[x_k, x_{k+1}]$ 内， $t = x - x_k \in [0, 1)$ 。

最近邻插值 (Nearest Neighbor)：取离 x 最近的采样值， $g(x)$ 是阶梯函数

$$g(x) = f(x_k), \quad k = \arg \min_j |x - x_j|$$

线性插值 (Linear)：用相邻两点连直线

$$g(x) = (1 - t)f(x_k) + tf(x_{k+1})$$

Cubic 插值：在每个区间上用三次多项式，由两端函数值与一阶导数连续共四个条件定出系数

$$g(x) \Big|_{[x_k, x_{k+1}]} = a_3(x - x_k)^3 + a_2(x - x_k)^2 + a_1(x - x_k) + a_0$$

$$g(x_k) = f(x_k), \quad g(x_{k+1}) = f(x_{k+1}), \quad g'(x_k^-) = g'(x_k^+), \quad g'(x_{k+1}^-) = g'(x_{k+1}^+)$$

插值的方法有最近邻插值法，线性插值法。最近邻插值就是直接把最近邻居的数值搬过来，形成类似直方图的函数状态；比这个效果稍好的是线性插值，可以至少具有丰富的变化和导数。效果更好的是选取分段的高次函数，比如 Cubic 插值选用三次函数保证一阶连续。

放到图像上采样的插值算法中，双线性插值法是较为常用的，只需要知道周围四个邻居的数值，但是注意，双线性插值是一种非线性插值，结果中有交叉项。如果要追求好的效果，用 Bicubic 插值。

双线性插值 (Bilinear)：用周围四个邻居。记 $u = x - i$, $v = y - j$, $(u, v) \in [0, 1]^2$

$$g(x, y) = (1 - u)(1 - v)f(i, j) + u(1 - v)f(i + 1, j) + (1 - u)v f(i, j + 1) + uv f(i + 1, j + 1)$$

写成矩阵形式，交叉项 uv 出现在展开后的二次项中：

$$g(x, y) = \begin{bmatrix} 1 - u & u \end{bmatrix} \begin{bmatrix} f(i, j) & f(i, j + 1) \\ f(i + 1, j) & f(i + 1, j + 1) \end{bmatrix} \begin{bmatrix} 1 - v \\ v \end{bmatrix}$$

Bicubic 插值：用周围 $4 \times 4 = 16$ 个邻居，两个方向分别套用同一个三次核 W ，可分离地写成

$$g(x, y) = \sum_{m=-1}^2 \sum_{n=-1}^2 f(i + m, j + n) W(u - m) W(v - n)$$

其中 W 为三次卷积核 (a 通常取 -0.5)

$$W(s) = \begin{cases} (a + 2)|s|^3 - (a + 3)|s|^2 + 1, & |s| \leq 1 \\ a|s|^3 - 5a|s|^2 + 8a|s| - 4a, & 1 < |s| < 2 \\ 0, & |s| \geq 2 \end{cases}$$

3.3.3 Joint Bilateral Upsampling

Motivation: Why Upsample Jointly 深度估计 (立体匹配 stereo matching、多视图立体 multi-view stereo 等) 需要为每个像素在一系列候选视差 (disparity) 上做匹配，代价随像素数增长，通常是整个流程中最贵的一步。如果最终只需要一张低分辨率的深度图，一个常见的加速方案是把流程拆成三步：

1. 对输入图像降采样 (downsample)，得到低分辨率彩色图；
2. 在低分辨率上估计深度图 (estimate the depth image)；
3. 把深度图上采样 (upsample) 回原始分辨率。

前两步的代价大致与像素数成正比，因此把最贵的深度估计放到低分辨率上做，代价可以显著下降，这就是 “for significant speedup” 的含义。问题出在第三步：直接用上一节的最近邻、双线性或 Bicubic 插值放大深度图，并不能得到满意的结果。这些插值只关心样本之间的空间距离，完全不知道图像内容；而深度图在物体边界处存在跳变 (discontinuity)，插值核会把边界两侧的样本一起平均，于是边界被抹成一条斜坡，与真实的三维结构不符。最近邻插值虽然不会模糊，但会产生块状锯齿。

Joint Bilateral Upsampling

For significant speedup

- Downsample input image
- Estimate the depth image
- Upsample the depth image

How to upsample the results?

- Reuse the edge information in the original input image




图 4: 联合双边上采样的动机: 降采样—估计深度—上采样, 上采样时复用原始输入图像的边缘信息

于是自然的想法是: 不要只在深度图内部插值, 而是**复用原始输入图像中的边缘信息** (reuse the edge information in the original input image)。物体的边界在彩色图和深度图上出现在同一位置, 高分辨率彩色图仍然保留着低分辨率深度图已经丢失的边界位置, 因此可以把它作为引导图 (guide), 让插值权重在颜色发生跳变的地方被截断。

The JBU Formula Kopf 等人把上一节双边滤波的思想搬到上采样任务上, 提出了联合双边上采样 (Joint Bilateral Upsampling, JBU)。设低分辨率深度图为 S , 高分辨率彩色引导图为 $\tilde{I}$, 则高分辨率深度图上像素 p 的取值为

$$\tilde{S}_p = \frac{1}{k_p} \sum_{q_{\downarrow} \in \Omega} S_{q_{\downarrow}} f(\|p_{\downarrow} - q_{\downarrow}\|) g(\|\tilde{I}_p - \tilde{I}_q\|)$$

其中各符号的含义为:

- p : 高分辨率输出图上的目标像素; $p_{\downarrow}$ 是它在低分辨率网格上的对应坐标 ($\downarrow$ 表示低分辨率深度图中的坐标)。
- $q_{\downarrow}$: 低分辨率深度图中落在 $p_{\downarrow}$ 邻域 Ω 内的样本点, 求和遍历整个 Ω 。
- $S_{q_{\downarrow}}$: 该样本点的低分辨率深度值, 也就是被插值的信号。
- $\tilde{I}_p, \tilde{I}_q$: 高分辨率彩色引导图在对应位置的取值。
- f 与 g 都是高斯函数 (Gaussian function): f 作用在空间距离上, 是域核 (domain kernel); g 作用在颜色差上, 是值核 (range kernel)。
- k_p : 归一化因子 (normalization factor), 即所有权重之和 $k_p = \sum_{q_{\downarrow} \in \Omega} f g$, 使权重归一化到和为 1。

公式的结构与双边滤波完全一致，区别集中在两点：

- 空间项 f 是在**低分辨率**坐标上计算的， $\|p_{\downarrow} - q_{\downarrow}\|$ 度量的是样本到目标位置的距离。它扮演插值核的角色：距离越远权重越小，从而在稀疏的低分辨率样本之间平滑地重建出高分辨率的取值。
- 颜色项 g 取的是**高分辨率**彩色图。当样本跨过物体边界时， $\|\tilde{I}_p - \tilde{I}_q\|$ 很大， g 迅速趋近于 0，跨越边界的样本被排除在平均之外。

因此 f 负责“插值”（保持平滑）， g 负责“保边”（在颜色跳变处截断），二者相乘得到一个形状随位置变化、由引导图决定的插值核。这正是它比固定核的 Bicubic 插值更贴合真实边界的原因。





图 5: 联合双边上采样在一维信号上的过程：左列为信号（上：低分辨率深度；下：高分辨率彩色），中列为两个高斯权重 f 、 g ，右列为相乘后的权重与上采样结果 $\tilde{S}_p$

上图把公式在一维信号上逐步展开。第一行是空间部分：低分辨率深度图在边界处有一个跳变，目标位置 p 用蓝色星号标出，落在低的那个台阶上；空间权重 f 是以 $p_{\downarrow}$ 为中心的高斯；它与信号相乘后，在低分辨率样本上得到一条以 p 为中心的权重曲线。第二行是颜色部分：高分辨率彩色图在对应位置也有一个跳变，颜色权重 g 在颜色与 $\tilde{I}_p$ 相同的区域接近 1，一跨过边界就掉到 0；于是把 f 与 g 相乘得到的组合权重中，位于边界另一侧的样本权重被压制为 0。最终结果是高分辨率深度图 $\tilde{S}_p$ ：既在物体内部平滑，又保持了锐利的边界，而且边界位置正好落在彩色图的边缘上。

Joint Bilateral Upsampling



Kopf, Johannes, et al. "Joint bilateral upsampling." ACM Transactions on Graphics, 2007

图 6: 四种上采样方法在深度图边界处的对比（上排为放大的深度图区域，下排为对应的高分辨率彩色图）

Comparison with Other Upsampling Methods 同一张低分辨率深度图用四种方法放大，效果差别很明显：

- **最近邻上采样 (Nearest Neighbor)**：直接复制最近样本，深度值不产生新的中间值，但边界走样成块状的锯齿，呈阶梯状；
- **双线性 / Bicubic 上采样**：结果平滑，但深度边界被抹成一条逐渐过渡的斜坡，与彩色图中的锐利边缘不再对齐；
- **高斯上采样 (Gaussian)**：本质上是各向同性的低通插值，模糊更严重，边界更加弥散；
- **联合双边上采样 (JBU)**：在物体内部平滑过渡，在边界处与彩色图的边缘对齐，得到既连续又锐利的深度图。

Discussion

- 与上一节的联合双边滤波相比，这里的“联合”体现在两个不同分辨率的信号上：被滤波的是低分辨率深度图，提供颜色相似性判据的却是高分辨率彩色图。若引导图就是被滤波图像本身、且两者分辨率相同，公式即退化为普通的双边滤波。
- 计算上，每个高分辨率像素只需要遍历一个小邻域 Ω （例如 4×4 个低分辨率样本），比直接在高分辨率上重新估计深度便宜得多，因此适合作为“低分辨率估计 + 高分辨率恢复”这一套流程的最后一步。

- 这种用引导图决定滤波核形状的思路后来被推广为引导滤波（Guided Filter）等边缘保持滤波方法，也常出现在深度图增强、深度上采样以及需要从低分辨率标注恢复高分辨率预测的任务中。

Kopf, Johannes, et al. “Joint bilateral upsampling.” *ACM Transactions on Graphics*, 2007.

3.3.4 Image Blending

这是 Laplacian 金字塔在图像混合中的重要应用。图像混合要让低频的噪声尽可能均匀混合，同时体现出高频部分的线条，物体等等，laplace 金字塔可以分开不同的频率，因此常常被用在类似的操作中。

具体做法分四步：

1. 对两张源图分别建立 Laplacian 金字塔 $\{L_i^A\}$ 、 $\{L_i^B\}$ ；
2. 对掩膜 M 建立 Gaussian 金字塔 $\{M_i\}$ ，逐级模糊相当于逐级加宽过渡带；
3. 在每一层分别混合 $L_i = M_i \odot L_i^A + (1 - M_i) \odot L_i^B$ ；
4. 把混合后的各层折叠（collapse，逐级上采样并相加）回一张图像。




图 7: Laplacian 金字塔融合：每一行是一个频带，两张图在该频带上按掩膜加权相加，最后把所有频带折叠回图像

图中每一行就是一个频带，自上而下由细到粗：最上面一行是最细的高频带，掩膜几乎还是硬边；越往下频带越粗，掩膜被模糊得越厉害，最下面一行只剩大范围的平滑过渡，混合的主要是颜色与亮度。这正是图中 Key Idea 的含义——“blend lower frequency bands over larger spatial ranges, high frequency bands over small spatial ranges”：低频用大范围过渡，所以看不到接缝；高频用小范围过渡，所以纹理

和边缘不会被糊掉。直接按掩膜逐像素加权会在边界留下可见的接缝，而先把掩膜模糊又会连带糊掉细节，金字塔融合用“过渡带宽度随频带变化”同时避开了这两个问题。

这也点出了金字塔表示的价值：同一个边界在不同频带上需要不同的空间尺度，只有先把图像拆成频带，才可能对它们分别处理 (Burt & Adelson, 1983)。

3.4 Image Transformation

Image Warping Image Warping 指的是对图像的几何变形，比如旋转，伸缩，拉伸，变形等等。要点在于如果直接映射原来图像到新图像，则会出现空洞或重叠现象。重点方法在于扫描目标图像，逆映射到原图的实数值，然后通过插值方法取得像素的数值，保证不会重复计算，全面覆盖。

Inverse Warping

For every pixel x' in $g(x')$

1. Compute the source location x with $\hat{h}(x')$
2. Resample $f(x)$ at location x and copy to $g(x')$

Implementation details

- $\hat{h}(x)$ is the inverse of $h(x)$
- Resample with bilinear interpolation




图 8: 反向映射：对目标图的每个像素 x' 用逆映射求出源位置 $x = \hat{h}(x')$ ，再在源图上重采样

对目标图像 $g(x')$ 中的每一个像素：

1. 用逆映射 $\hat{h}$ 算出它在源图中的位置 $x = \hat{h}(x')$ ；
2. 在源图 f 的该位置重采样 (resample)，把结果复制到 $g(x')$ 。

两个实现细节：

- $\hat{h}$ 是 h 的逆映射。如果反过来遍历源像素、算出目标位置再写过去，目标图上会出现空洞（相邻源像素被拉开）与重叠（多个源像素落到同一格）；反向映射则保证每个目标像素恰好被写入一次。
- 重采样用双线性插值： $\hat{h}(x')$ 通常不是整数坐标（图中下排的红点落在四个格点之间），需要由它周围四个源像素加权得到取值，也就是 3.3.2 节讲的双线性插值。

Image Morphing Image Morphing 指的是两个图像进行融合叠加的方法，实质上是分块的 Warping 和 blending。

Morphing 的具体步骤（源图 s 、目标图 u ，进度参数 $\mu \in [0, 1]$ ）：

1. 在两幅图上选取一一对应的特征点 (feature points), 各自做 Delaunay 三角剖分, 得到网格 T_s 、 T_u ;
2. 对三角形的位置做线性插值, 得到中间网格 $T = \mu T_s + (1 - \mu) T_u$;
3. 按 $T_s \rightarrow T$ 与 $T_u \rightarrow T$ 的对应关系, 在每个三角形内把两幅图分别 warp 成 $\tilde{s}$ 、 $\tilde{u}$ (三角形内部的映射由三个顶点唯一确定, 是仿射变换);
4. 把两幅已经对齐的图像按颜色混合, 输出 $o = \mu \tilde{s} + (1 - \mu) \tilde{u}$ 。

Image Morphing

- Given source and target image s & u .
- Select feature points on images, build Delaunay triangulations T_s & T_u .
- Morph the triangulations by linearly interpolating each triangle

$$T = \mu T_s + (1 - \mu) T_u.$$
- Warp image s/u in each triangle according to the transformation between T_s/T_u and T to get $\tilde{s}/\tilde{u}$.
- Get the final output image as

$$o = \mu \tilde{s} + (1 - \mu) \tilde{u}.$$




图 9: Image morphing: T_s 、 T_u 是源图与目标图的 Delaunay 三角剖分, 插值出中间网格后在每个三角形内 warp 并混合

μ 由 0 变到 1 时, 输出的几何形状与颜色同时从源图过渡到目标图: 前者靠 warping, 后者靠 cross-dissolve (线性混合), morphing 正是两者的组合。

4 Figure Detection

4.1 Edge Detection

Mathematical Principle and Matrix Discretization 边缘是图像中亮度发生突变 (不连续) 之处: 表面法向、深度、颜色、光照的不连续都会形成边缘, 而边缘携带了图像中大部分语义与形状信息, 因此它是最先被提取的特征。数学上把灰度图视作二维函数 $f(x, y)$, ”突变” 就是函数在某处变化剧烈, 用导数来度量。把沿 x 、 y 的偏导数堆叠起来即得梯度

$$\nabla f = \begin{bmatrix} f_x \\ f_y \end{bmatrix} = \begin{bmatrix} \partial f / \partial x \\ \partial f / \partial y \end{bmatrix}, \quad |\nabla f| = \sqrt{f_x^2 + f_y^2}, \quad \theta = \arctan \frac{f_y}{f_x}.$$

在一维剖面上, 边缘正对应一阶导数的极值; 到二维就是梯度幅值 $|\nabla f|$ 的大值, θ 给出边缘的法向。

图像是离散采样的，导数只能由差商近似。从泰勒展开 $f(x+h) = f(x) + f'(x)h + \frac{f''(x)}{2!}h^2 + \dots$ 出发，取 $h=1$ 得前向差分 $f_x \approx f(x+1, y) - f(x, y)$ ；若把 $x+1$ 与 $x-1$ 两处的展开相减，二阶项相消，得到中心差分

$$f_x \approx \frac{f(x+1, y) - f(x-1, y)}{2},$$

它一步就有 $O(h^2)$ 精度（前向差分只有 $O(h)$ ），因此实际中一律采用中心差分。

真正让导数能在计算机上“跑起来”的是矩阵离散化：差商不过是相邻像素的加权和，因而可以写成一个卷积核。一维情形是 $[-1 \ 1]$ （前向）与 $[-1 \ 0 \ 1]$ （中心）；二维时把一维核沿另一方向复制，再叠加平滑权，就得到

$$H_x^{\text{Prewitt}} = \begin{bmatrix} -1 & 0 & 1 \\ -1 & 0 & 1 \\ -1 & 0 & 1 \end{bmatrix}, \quad H_y^{\text{Prewitt}} = \begin{bmatrix} 1 & 1 & 1 \\ 0 & 0 & 0 \\ -1 & -1 & -1 \end{bmatrix},$$

$$H_x^{\text{Sobel}} = \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix}, \quad H_y^{\text{Sobel}} = \begin{bmatrix} 1 & 2 & 1 \\ 0 & 0 & 0 \\ -1 & -2 & -1 \end{bmatrix}.$$

于是求导退化为 3.2 节讲过的卷积滤波： $f_x = f * H_x$ ， $f_y = f * H_y$ 。核中的 ± 1 在做差商、0 在取中心、权重 2 与 1 在做平滑——Prewitt 与 Sobel 的唯一差别就在平滑权：Sobel 把中间行加倍，相当于在求导方向上再叠一个 $[1, 2, 1]$ 的二项式核，对噪声更稳健。

Partial Derivatives of an Image

- Partial Derivatives of an Image can be computed as image filtering

Other Differentiation Operations	Horizontal	Vertical
Prewitt	$\begin{bmatrix} -1 & 0 & 1 \\ -1 & 0 & 1 \\ -1 & 0 & 1 \end{bmatrix}$	$\begin{bmatrix} 1 & 1 & 1 \\ 0 & 0 & 0 \\ -1 & -1 & -1 \end{bmatrix}$
Sobel	$\begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix}$	$\begin{bmatrix} 1 & 2 & 1 \\ 0 & 0 & 0 \\ -1 & -2 & -1 \end{bmatrix}$

图 10: Prewitt 与 Sobel 的导数核：水平核（对 x 求导）与垂直核（对 y 求导）都是 3×3 矩阵，即离散化后的偏导算子

把 $|\nabla f|$ 阈值化即可得到边缘图（Sobel 边缘检测器），但阈值很脆弱、很难选：偏高会漏掉弱边缘，偏低又会把噪声当成边缘——这正是后面 Canny 用非极大值抑制与双阈值要解决的问题。

Noise Suppression and the Gaussian Derivative 噪声对导数是致命的。设观测图像为 $I_{i,j} = T_{i,j} + \epsilon_{i,j}$ ，其中 T 是真实图像， $\epsilon_{i,j} \sim N(0, \sigma^2)$ 是各像素独立同分布的噪声。用中心差分求导时，噪声被一并相减：

$$D_{i,j} = (T_{i,j+1} + \epsilon_{i,j+1}) - (T_{i,j-1} + \epsilon_{i,j-1}) = (T_{i,j+1} - T_{i,j-1}) + (\epsilon_{i,j+1} - \epsilon_{i,j-1}).$$

后一项是两个独立高斯之差，仍是高斯，但方差相加： $\epsilon_{i,j} - \epsilon_{k,l} \sim N(0, 2\sigma^2)$ ，即方差翻倍，标准差被放大 $\sqrt{2}$ 倍。平坦区域里真实差分近似为零，导数图便由纯噪声主导，真正的边缘被完全淹没。

解决办法是”先平滑、再求导”：先用高斯核 g 平滑图像再做微分，即求 $\frac{d}{dx}(f * g)$ 。由卷积与微分可交换，

$$\frac{d}{dx}(f * g) = f * \frac{dg}{dx},$$

所以两趟卷积能合并成一趟：只需先把高斯核求导得到”高斯导数”核 $\frac{dg}{dx}$ （一维上是一侧为正、一侧为负的反对称波形），再与图像卷积一次，就同时完成了去噪与求导。二维下对应两个核 $G_x = \partial G_\sigma / \partial x$ 与 $G_y = \partial G_\sigma / \partial y$ ，按网格离散化就是对采样点直接求偏导：

$$G_x[i, j] = -\frac{i}{\sigma^2} e^{-\frac{i^2+j^2}{2\sigma^2}}, \quad G_y[i, j] = -\frac{j}{\sigma^2} e^{-\frac{i^2+j^2}{2\sigma^2}},$$

于是 $f_x = f * G_x$ 、 $f_y = f * G_y$ ，一个水平、一个垂直。

Let's Make It One Pass (1D)




图 11: 高斯导数: $\frac{d}{dx}(f * g) = f * \frac{dg}{dx}$ 把去噪与求导合并为一趟卷积；右侧是二维的 $\frac{\partial G_\sigma}{\partial x}$ 与 $\frac{\partial G_\sigma}{\partial y}$

代价是尺度上的两难： σ 越大去噪越彻底，但边缘同时被抹平，导数峰展宽、定位精度下降（课件分别用 1、3、7 像素的高斯核：越小噪声残留越多，越大边缘越糊）。”去噪”与”保边定位”无法兼得， σ 只能折中——这也解释了为什么 Canny 的第一步（灰度化 + 高斯滤波）与 Harris 角点的预处理都要先做高斯平滑。

Canny Edge Detector Canny 检测器把前面几节的工具串成一条六步流水线，目标是得到“细、连续、定位准”的边缘：

1. **预处理：灰度化 + 高斯模糊**。先把彩色图转成灰度图（边缘本是由亮度突变定义的），再用高斯核平滑以抑制噪声——这正是上一段的动机：求导会放大噪声，所以必须先平滑。
2. **中心差分求梯度图**。用 Sobel 的中心差分算出 G_x 、 G_y （而不用前向差分，因为中心差分精度更高）。 G_x 突出竖直边缘、 G_y 突出水平边缘。
3. **计算梯度幅值**。 $|\nabla f| = \sqrt{G_x^2 + G_y^2}$ ，即边缘强度图。
4. **非极大值抑制（Non-Maximum Suppression）**。幅值图上的边缘是粗的：边缘附近一整条带上的像素幅值都很大。做法是遍历幅值矩阵，只保留沿**梯度方向**的局部极大值。对像素 q ，沿梯度方向取它两侧的邻居 p 与 r ；梯度方向一般不落在整数格点上，故 r 由相邻两点线性插值得到 $r = \alpha b + (1 - \alpha)a$ 。当且仅当 $q > p$ 且 $q > r$ 时保留 q ，否则置零——一条粗边就被削成单像素宽。
5. **双阈值**。设高阈值（如 0.7）与低阈值（如 0.3）：高于高阈值的像素确定是边缘（强边缘），低于低阈值的一定不是，介于两者之间的是**弱边缘**，留给下一步判定。用双阈值取代单阈值，正是为了化解上一段末尾说的“阈值难选”：单阈值偏高会漏掉弱边缘，偏低又会引入噪声。
6. **滞后边缘跟踪（Edge Tracking by Hysteresis）**。与强边缘相连的弱边缘判为真实边缘而保留，不与任何强边缘相连的弱边缘则丢弃。这一步让边缘在弱对比处仍能连续延伸，同时排除孤立的噪声响应。

Canny Edge Detector

4. Non-Maximum Suppression

- The gradient magnitude produced results in thick edges. We perform non-maximum suppression to thin out the edges.
- Go through all the points on the gradient intensity matrix, **find and only keep** the pixels with the maximum value in the edge directions.
- Example: keep q if $q > p$ and $q > r$





图 12: 非极大值抑制：沿梯度方向比较 q 与两侧的 p 、 r (r 由 a 、 b 线性插值)，只保留局部极大值，把粗边缘削成单像素宽

Applications of the Canny Detector Canny 给出的单像素、连续的边缘图本身就是物体的”线稿”，因此常被当作下游任务的条件输入：

- **草图生成与三维形状生成。** Locally Attentional SDF Diffusion for Controllable 3D Shape Generation (SIGGRAPH 2023) 用 Canny 从渲染图中提取线稿，再以线稿为条件生成可控的三维形状。
- **文本到图像的附加控制。** Adding Conditional Control to Text-to-Image Diffusion Models 中用 Canny 边缘图作为空间条件注入扩散模型，于是”一张线稿 + 一句文本描述”就能精确控制生成图像的构图。
- **通用轮廓提取。** 图像编辑的选区引导、工业检测的缺陷轮廓、多视图几何中的特征线提取等，都把 Canny 当作默认的边缘算子。

Applications of Canny Edge Detector



Use Canny edge detector to generate sketches

Locally Attentional SDF Diffusion for Controllable 3D Shape Generation, SIGGRAPH 2023

图 13: 应用一：用 Canny 从渲染图提取线稿，作为三维形状生成的可控条件 (Locally Attentional SDF Diffusion, SIGGRAPH 2023)

Adding Conditional Control to Text-to-Image Diffusion Models

Lvmin Zhang, Anyi Rao, and Maneesh Agrawala

Stanford University

{lvmin, anyirao, maneesh}@cs.stanford.edu



图 14: 应用二: Canny 线稿作为扩散模型的空间控制条件, 同一张线稿配不同文本可生成不同风格的图像 (ControlNet / Adding Conditional Control to Text-to-Image Diffusion Models)

不过课件最后提醒: **边缘检测至今仍是一个未解决的问题**。人眼能把图中的物体轮廓干净地分割出来, 而梯度幅值图在物体内部与背景处的杂散响应同样强烈, 二者相差甚远。这也正是接下来要从边缘转向更能刻画局部结构的特征——角点与 blob——的原因。