

两个高维随机变量的联合高斯分布

表达式、推导与所需的线性代数

讲义

2026 年 9 月 30 日

摘要

本讲义的目标是把下面这个问题讲透：设 $\mathbf{x} \in \mathbb{R}^n$ 、 $\mathbf{y} \in \mathbb{R}^m$ 是两个高维随机向量，它们服从联合高斯分布，那么联合密度 $P(\mathbf{x}, \mathbf{y})$ 长什么样？由它如何推出边缘分布 $P(\mathbf{x})$ 与条件分布 $P(\mathbf{y} | \mathbf{x})$ ？推导中用到的核心工具是对称正定矩阵、分块矩阵与 Schur 补、矩阵形式的配方法，以及多重积分的换元公式。第 2 节系统地准备这些线性代数知识；第 3 节建立多元高斯分布；第 4 节给出 $P(\mathbf{x}, \mathbf{y})$ 的完整推导；第 5 节以二维情形和线性高斯模型为例说明结果。

目录

1 记号与约定	2
2 线性代数预备知识	2
2.1 内积、二次型与对称矩阵	2
2.2 谱定理：对称矩阵可正交对角化	3
2.3 正定与半正定矩阵	3
2.4 行列式与逆的基本性质	4
2.5 分块矩阵与 Schur 补	4
2.6 二次型的分块展开与矩阵配方法	5
2.7 多重积分的换元与雅可比行列式	6
2.8 一元高斯积分	6
3 多元高斯分布	6
3.1 从一元到多元	6
3.2 归一化常数的推导	7
3.3 均值与协方差	7
3.4 仿射变换保持高斯性	8
3.5 几何图像	8

1 记号与约定	2
4 两个高维随机变量的联合高斯分布 $P(\mathbf{x}, \mathbf{y})$	8
4.1 设定与联合密度	8
4.2 第一步：用 Schur 补写出精度矩阵	9
4.3 第二步：展开指数	9
4.4 第三步：联合密度的乘积分解	10
4.5 边缘分布	10
4.6 条件分布	11
4.7 独立性	11
5 例子与应用	11
5.1 二维情形： $n = m = 1$	11
5.2 线性高斯模型：如何”制造”一个联合高斯	12
6 小结	12

1 记号与约定

全文中，粗体小写字母（如 $\mathbf{x}, \boldsymbol{\mu}$ ）表示列向量，粗体大写字母（如 $\boldsymbol{\Sigma}, \mathbf{A}$ ）表示矩阵，普通斜体字母表示标量。 $\mathbf{A}^\top$ 表示转置， $\mathbf{A}^{-1}$ 表示逆， $\det \mathbf{A}$ （或 $|\mathbf{A}|$ ）表示行列式， $\mathbf{I}_n$ 表示 n 阶单位矩阵。向量 $\mathbf{x} \in \mathbb{R}^n$ 的分量记为 $x_1, \dots, x_n$ 。

对随机向量 $\mathbf{x}$ ，其均值向量与协方差矩阵定义为

$$\mathbb{E}[\mathbf{x}] = \begin{pmatrix} \mathbb{E}[x_1] \\ \vdots \\ \mathbb{E}[x_n] \end{pmatrix}, \quad \text{Cov}[\mathbf{x}] = \mathbb{E}[(\mathbf{x} - \mathbb{E}\mathbf{x})(\mathbf{x} - \mathbb{E}\mathbf{x})^\top] \in \mathbb{R}^{n \times n},$$

即 $\text{Cov}[\mathbf{x}]$ 的 (i, j) 元是 $\text{Cov}(x_i, x_j)$ 。两个随机向量之间的互协方差为 $\text{Cov}[\mathbf{x}, \mathbf{y}] = \mathbb{E}[(\mathbf{x} - \mathbb{E}\mathbf{x})(\mathbf{y} - \mathbb{E}\mathbf{y})^\top] \in \mathbb{R}^{n \times m}$ ，显然 $\text{Cov}[\mathbf{y}, \mathbf{x}] = \text{Cov}[\mathbf{x}, \mathbf{y}]^\top$ 。

2 线性代数预备知识

本节内容是后面所有推导的”零件”。读者若已熟悉，可以直接跳到第 3 节，需要时再回来查阅。

2.1 内积、二次型与对称矩阵

定义 2.1 (内积与范数). $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$ 的内积为 $\mathbf{x}^\top \mathbf{y} = \sum_i x_i y_i$ ，范数为 $\|\mathbf{x}\| = \sqrt{\mathbf{x}^\top \mathbf{x}}$ 。

定义 2.2 (二次型). 给定 $\mathbf{A} \in \mathbb{R}^{n \times n}$ ，函数 $q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x} = \sum_{i,j} A_{ij} x_i x_j$ 称为由 $\mathbf{A}$ 确定的二次型。

由于 $\mathbf{x}^\top \mathbf{A} \mathbf{x}$ 是一个标量, 它等于自身的转置: $\mathbf{x}^\top \mathbf{A} \mathbf{x} = (\mathbf{x}^\top \mathbf{A} \mathbf{x})^\top = \mathbf{x}^\top \mathbf{A}^\top \mathbf{x}$ 。因此

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \mathbf{x}^\top \left(\frac{\mathbf{A} + \mathbf{A}^\top}{2} \right) \mathbf{x},$$

也就是说, 二次型只“看得见”矩阵的对称部分。所以在讨论二次型时, 总可以不失一般性地假定 $\mathbf{A}$ 对称 ($\mathbf{A} = \mathbf{A}^\top$)。高斯分布指数中的二次型正是由对称矩阵 (协方差的逆) 确定的。

2.2 谱定理: 对称矩阵可正交对角化

定理 2.3 (谱定理). 设 $\mathbf{A} \in \mathbb{R}^{n \times n}$ 对称, 则存在正交矩阵 $\mathbf{Q}$ (即 $\mathbf{Q}^\top \mathbf{Q} = \mathbf{Q} \mathbf{Q}^\top = \mathbf{I}$) 与实对角矩阵 $\mathbf{\Lambda} = \text{diag}(\lambda_1, \dots, \lambda_n)$, 使得

$$\mathbf{A} = \mathbf{Q} \mathbf{\Lambda} \mathbf{Q}^\top = \sum_{i=1}^n \lambda_i \mathbf{q}_i \mathbf{q}_i^\top,$$

其中 λ_i 是 $\mathbf{A}$ 的特征值, $\mathbf{q}_i$ ($\mathbf{Q}$ 的第 i 列) 是对应的单位特征向量。

这个定理给出了理解对称矩阵的“坐标系”: 在由特征向量 $\mathbf{q}_1, \dots, \mathbf{q}_n$ 张成的正交坐标系下, $\mathbf{A}$ 就是纯粹的逐坐标伸缩。令 $\mathbf{w} = \mathbf{Q}^\top \mathbf{x}$ (即把 $\mathbf{x}$ 在新坐标系下展开), 则

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = \mathbf{x}^\top \mathbf{Q} \mathbf{\Lambda} \mathbf{Q}^\top \mathbf{x} = \mathbf{w}^\top \mathbf{\Lambda} \mathbf{w} = \sum_{i=1}^n \lambda_i w_i^2. \quad (1)$$

二次型在新坐标下没有交叉项, 这是后面计算高斯积分的关键。

2.3 正定与半正定矩阵

定义 2.4 (正定、半正定). 对称矩阵 $\mathbf{A}$ 称为半正定 (记 $\mathbf{A} \succeq 0$), 若对一切 $\mathbf{x}$ 有 $\mathbf{x}^\top \mathbf{A} \mathbf{x} \geq 0$; 称为正定 (记 $\mathbf{A} \succ 0$), 若对一切 $\mathbf{x} \neq \mathbf{0}$ 有 $\mathbf{x}^\top \mathbf{A} \mathbf{x} > 0$ 。

命题 2.5. 设 $\mathbf{A}$ 对称, 则

- (1) $\mathbf{A} \succeq 0$ 当且仅当所有特征值 $\lambda_i \geq 0$; $\mathbf{A} \succ 0$ 当且仅当所有 $\lambda_i > 0$ 。
- (2) 若 $\mathbf{A} \succ 0$, 则 $\mathbf{A}$ 可逆, $\mathbf{A}^{-1} \succ 0$, 且 $\det \mathbf{A} = \prod_i \lambda_i > 0$ 。
- (3) 若 $\mathbf{A} \succ 0$, 则存在唯一的对称正定矩阵 $\mathbf{A}^{1/2}$ 使 $\mathbf{A}^{1/2} \mathbf{A}^{1/2} = \mathbf{A}$, 具体为 $\mathbf{A}^{1/2} = \mathbf{Q} \mathbf{\Lambda}^{1/2} \mathbf{Q}^\top$, 其中 $\mathbf{\Lambda}^{1/2} = \text{diag}(\sqrt{\lambda_i})$ 。类似地记 $\mathbf{A}^{-1/2} = (\mathbf{A}^{1/2})^{-1} = \mathbf{Q} \mathbf{\Lambda}^{-1/2} \mathbf{Q}^\top$ 。
- (4) 对任意矩阵 $\mathbf{B} \in \mathbb{R}^{n \times k}$, $\mathbf{B} \mathbf{B}^\top \succeq 0$; 若 $\mathbf{B}$ 的行满秩 (秩为 n), 则 $\mathbf{B} \mathbf{B}^\top \succ 0$ 。

证明. (1) 由 (1), $\mathbf{x}^\top \mathbf{A} \mathbf{x} = \sum_i \lambda_i w_i^2$, 而 $\mathbf{w} = \mathbf{Q}^\top \mathbf{x}$ 取遍 $\mathbb{R}^n$ 且 $\mathbf{w} = \mathbf{0} \iff \mathbf{x} = \mathbf{0}$, 结论显然。(2) 特征值全正故行列式为正, 从而可逆; $\mathbf{A}^{-1} = \mathbf{Q} \mathbf{\Lambda}^{-1} \mathbf{Q}^\top$ 的特征值为 $1/\lambda_i > 0$ 。(3) 直接验证 $(\mathbf{Q} \mathbf{\Lambda}^{1/2} \mathbf{Q}^\top)^2 = \mathbf{Q} \mathbf{\Lambda} \mathbf{Q}^\top = \mathbf{A}$; 唯一性略。(4) $\mathbf{x}^\top \mathbf{B} \mathbf{B}^\top \mathbf{x} = \|\mathbf{B}^\top \mathbf{x}\|^2 \geq 0$, 且当 $\mathbf{B}^\top$ 是单射 (即 $\mathbf{B}$ 行满秩) 时, $\mathbf{x} \neq \mathbf{0} \Rightarrow \mathbf{B}^\top \mathbf{x} \neq \mathbf{0}$ 。□

注 2.6. 协方差矩阵总是半正定的: 对任意 $\mathbf{a} \in \mathbb{R}^n$, $\mathbf{a}^\top \text{Cov}[\mathbf{x}] \mathbf{a} = \text{Var}(\mathbf{a}^\top \mathbf{x}) \geq 0$ 。本讲义只讨论协方差矩阵正定 (即“非退化”) 的高斯分布, 此时密度函数存在。

2.4 行列式与逆的基本性质

后面反复使用的性质有：

$$\begin{aligned} \det(\mathbf{AB}) &= \det \mathbf{A} \det \mathbf{B}, & \det(\mathbf{A}^\top) &= \det \mathbf{A}, & \det(\mathbf{A}^{-1}) &= (\det \mathbf{A})^{-1}, \\ (\mathbf{AB})^{-1} &= \mathbf{B}^{-1} \mathbf{A}^{-1}, & (\mathbf{A}^\top)^{-1} &= (\mathbf{A}^{-1})^\top, & \det(c\mathbf{A}) &= c^n \det \mathbf{A} \quad (\mathbf{A} \in \mathbb{R}^{n \times n}). \end{aligned}$$

特别地，若 $\mathbf{A}$ 对称正定，则 $\det(\mathbf{A}^{1/2}) = \sqrt{\det \mathbf{A}}$, $\det(\mathbf{A}^{-1/2}) = (\det \mathbf{A})^{-1/2}$ 。

对角块矩阵与三角块矩阵的行列式也很简单：

$$\det \begin{pmatrix} \mathbf{A} & \mathbf{0} \\ \mathbf{0} & \mathbf{D} \end{pmatrix} = \det \mathbf{A} \det \mathbf{D}, \quad \det \begin{pmatrix} \mathbf{I} & \mathbf{B} \\ \mathbf{0} & \mathbf{I} \end{pmatrix} = \det \begin{pmatrix} \mathbf{I} & \mathbf{0} \\ \mathbf{C} & \mathbf{I} \end{pmatrix} = 1.$$

2.5 分块矩阵与 Schur 补

这是本讲义最核心的线性代数工具。设

$$\mathbf{M} = \begin{pmatrix} \mathbf{A} & \mathbf{B} \\ \mathbf{C} & \mathbf{D} \end{pmatrix}, \quad \mathbf{A} \in \mathbb{R}^{n \times n}, \mathbf{D} \in \mathbb{R}^{m \times m}, \mathbf{A} \text{ 可逆}.$$

定义 2.7 (Schur 补). $\mathbf{A}$ 在 $\mathbf{M}$ 中的 Schur 补定义为 $\mathbf{M}/\mathbf{A} := \mathbf{D} - \mathbf{CA}^{-1}\mathbf{B} \in \mathbb{R}^{m \times m}$ 。

Schur 补的来源是”分块高斯消元”：用第一块行消去第二块行中的 $\mathbf{C}$ 。写成矩阵语言就是下面的分块 LDU 分解。

引理 2.8 (分块 LDU 分解). 若 $\mathbf{A}$ 可逆，记 $\mathbf{S} = \mathbf{D} - \mathbf{CA}^{-1}\mathbf{B}$ ，则

$$\begin{pmatrix} \mathbf{A} & \mathbf{B} \\ \mathbf{C} & \mathbf{D} \end{pmatrix} = \begin{pmatrix} \mathbf{I} & \mathbf{0} \\ \mathbf{CA}^{-1} & \mathbf{I} \end{pmatrix} \begin{pmatrix} \mathbf{A} & \mathbf{0} \\ \mathbf{0} & \mathbf{S} \end{pmatrix} \begin{pmatrix} \mathbf{I} & \mathbf{A}^{-1}\mathbf{B} \\ \mathbf{0} & \mathbf{I} \end{pmatrix}. \quad (2)$$

证明. 直接把右边乘开：中间两项之积为 $\begin{pmatrix} \mathbf{A} & \mathbf{B} \\ \mathbf{0} & \mathbf{S} \end{pmatrix}$ ，再左乘第一项得

$$\begin{pmatrix} \mathbf{A} & \mathbf{B} \\ \mathbf{C} & \mathbf{CA}^{-1}\mathbf{B} + \mathbf{S} \end{pmatrix} = \begin{pmatrix} \mathbf{A} & \mathbf{B} \\ \mathbf{C} & \mathbf{D} \end{pmatrix}.$$

□

由此立刻得到两个重要推论。

定理 2.9 (分块行列式). 若 $\mathbf{A}$ 可逆，则 $\det \mathbf{M} = \det \mathbf{A} \cdot \det(\mathbf{D} - \mathbf{CA}^{-1}\mathbf{B})$ 。

证明. 对 (2) 两边取行列式，两个三角块矩阵的行列式为 1，对角块矩阵的行列式为 $\det \mathbf{A} \det \mathbf{S}$ 。□

定理 2.10 (分块求逆). 若 $\mathbf{A}$ 与 $\mathbf{S} = \mathbf{D} - \mathbf{CA}^{-1}\mathbf{B}$ 都可逆，则 $\mathbf{M}$ 可逆，且

$$\mathbf{M}^{-1} = \begin{pmatrix} \mathbf{A}^{-1} + \mathbf{A}^{-1}\mathbf{BS}^{-1}\mathbf{CA}^{-1} & -\mathbf{A}^{-1}\mathbf{BS}^{-1} \\ -\mathbf{S}^{-1}\mathbf{CA}^{-1} & \mathbf{S}^{-1} \end{pmatrix}. \quad (3)$$

证明. 对 (2) 逐项求逆并反序相乘 (注意 $\begin{pmatrix} I & B' \\ 0 & I \end{pmatrix}^{-1} = \begin{pmatrix} I & -B' \\ 0 & I \end{pmatrix}$):

$$M^{-1} = \begin{pmatrix} I & -A^{-1}B \\ 0 & I \end{pmatrix} \begin{pmatrix} A^{-1} & 0 \\ 0 & S^{-1} \end{pmatrix} \begin{pmatrix} I & 0 \\ -CA^{-1} & I \end{pmatrix},$$

乘开即得 (3). $\square$

对称的情形 (对应协方差矩阵) 值得单独记住: 若 M 对称, 即 $C = B^\top$ 、 $A = A^\top$ 、 $D = D^\top$, 则 $S = D - B^\top A^{-1}B$ 也对称, 且

$$M^{-1} = \begin{pmatrix} A^{-1} + A^{-1}BS^{-1}B^\top A^{-1} & -A^{-1}BS^{-1} \\ -S^{-1}B^\top A^{-1} & S^{-1} \end{pmatrix}.$$

命题 2.11. 若对称矩阵 $M = \begin{pmatrix} A & B \\ B^\top & D \end{pmatrix} \succ 0$, 则 $A \succ 0, D \succ 0$, 且 Schur 补 $S = D - B^\top A^{-1}B \succ 0$.

证明. 取 $z = (x^\top, 0^\top)^\top$ 得 $x^\top Ax = z^\top Mz > 0$ ($x \neq 0$), 故 $A \succ 0$; 同理 $D \succ 0$. 对 S : 由 (2), 令 $L = \begin{pmatrix} I & 0 \\ B^\top A^{-1} & I \end{pmatrix}$, 则 $M = L \begin{pmatrix} A & 0 \\ 0 & S \end{pmatrix} L^\top$, 于是 $\begin{pmatrix} A & 0 \\ 0 & S \end{pmatrix} = L^{-1}ML^{-\top} \succ 0$, 其右下块 $S \succ 0$. $\square$

2.6 二次型的分块展开与矩阵配方法

设 M 如上对称正定, $z = (u^\top, v^\top)^\top$, $u \in \mathbb{R}^n$, $v \in \mathbb{R}^m$. 把 $z^\top Mz$ 按块展开:

$$z^\top Mz = u^\top Au + 2u^\top Bv + v^\top Dv.$$

把它看成 v 的二次函数并”配方”。一元情形 $dv^2 + 2bv + a$ 配方得 $d(v + b/d)^2 + a - b^2/d$; 矩阵情形完全平行:

引理 2.12 (矩阵配方法). 设 $D \succ 0$, 则对任意 v, b ,

$$v^\top Dv + 2b^\top v = (v + D^{-1}b)^\top D(v + D^{-1}b) - b^\top D^{-1}b.$$

证明. 右边展开: $v^\top Dv + 2b^\top D^{-1}Dv + b^\top D^{-1}DD^{-1}b - b^\top D^{-1}b$, 利用 D 对称及 $D^{-1}D = I$ 化简即得. $\square$

不过在 Gauss 分布的推导中, 更方便的是直接用 LDU 分解 (2) 得到下面的恒等式, 它一步就把二次型拆成”只含 u 的部分”与”含 v 的完全平方”。

命题 2.13 (二次型的 Schur 分解). 设 $M = \begin{pmatrix} A & B \\ B^\top & D \end{pmatrix} \succ 0$, $S = D - B^\top A^{-1}B$, 则

$$\begin{pmatrix} u \\ v \end{pmatrix}^\top M^{-1} \begin{pmatrix} u \\ v \end{pmatrix} = u^\top A^{-1}u + (v - B^\top A^{-1}u)^\top S^{-1}(v - B^\top A^{-1}u). \quad (4)$$

证明. 由定理 2.10 证明中的分解式,

$$M^{-1} = L^{-\top} \begin{pmatrix} A^{-1} & \mathbf{0} \\ \mathbf{0} & S^{-1} \end{pmatrix} L^{-1}, \quad L^{-1} = \begin{pmatrix} I & \mathbf{0} \\ -B^{\top} A^{-1} & I \end{pmatrix}.$$

计算 $L^{-1} \begin{pmatrix} u \\ v \end{pmatrix} = \begin{pmatrix} u \\ v - B^{\top} A^{-1} u \end{pmatrix}$, 代入即得。 $\square$

注意 (4) 右边第一项与 v 无关, 第二项是关于 v 的、以 $B^{\top} A^{-1} u$ 为中心、以 S^{-1} 为”精度”的二次型。这正是”边缘 $\times$ 条件”结构的代数根源。

2.7 多重积分的换元与雅可比行列式

定理 2.14 (线性换元). 设 $A \in \mathbb{R}^{n \times n}$ 可逆, $b \in \mathbb{R}^n$, $g: \mathbb{R}^n \rightarrow \mathbb{R}$ 可积。作换元 $x = Aw + b$, 则

$$\int_{\mathbb{R}^n} g(x) dx = |\det A| \int_{\mathbb{R}^n} g(Aw + b) dw.$$

直观理解: 线性映射 $w \mapsto Aw$ 把单位体积放大为 $|\det A|$ 倍, 所以体积元 $dx = |\det A| dw$ 。相应地, 若随机向量 w 有密度 p_w , 而 $x = Aw + b$ (A 可逆), 则 x 的密度为

$$p_x(x) = \frac{1}{|\det A|} p_w(A^{-1}(x - b)). \quad (5)$$

2.8 一元高斯积分

引理 2.15. $\int_{-\infty}^{\infty} e^{-t^2/2} dt = \sqrt{2\pi}$, 更一般地对 $\lambda > 0$, $\int_{-\infty}^{\infty} e^{-\lambda t^2/2} dt = \sqrt{2\pi/\lambda}$ 。

证明. 记 $I = \int e^{-t^2/2} dt$, 则 $I^2 = \iint e^{-(s^2+t^2)/2} ds dt$, 换极坐标 $s = r \cos \theta, t = r \sin \theta, ds dt = r dr d\theta$, 得 $I^2 = \int_0^{2\pi} \int_0^{\infty} e^{-r^2/2} r dr d\theta = 2\pi$ 。第二式令 $t = s/\sqrt{\lambda}$ 即得。 $\square$

3 多元高斯分布

3.1 从一元到多元

一元高斯分布 $\mathcal{N}(\mu, \sigma^2)$ 的密度为

$$p(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right).$$

指数中的 $(x-\mu)^2/\sigma^2$ 可写作 $(x-\mu)(\sigma^2)^{-1}(x-\mu)$, 归一化常数中的 σ^2 是”协方差”。把这两处的 σ^2 换成协方差矩阵 Σ , 就得到多元情形。

定义 3.1 (多元高斯分布). 设 $\mu \in \mathbb{R}^n$, $\Sigma \in \mathbb{R}^{n \times n}$ 对称正定。若随机向量 $x \in \mathbb{R}^n$ 的密度为

$$\mathcal{N}(x; \mu, \Sigma) = \frac{1}{(2\pi)^{n/2} (\det \Sigma)^{1/2}} \exp\left(-\frac{1}{2}(x-\mu)^{\top} \Sigma^{-1} (x-\mu)\right), \quad (6)$$

则称 x 服从均值为 μ 、协方差为 Σ 的多元高斯分布, 记 $x \sim \mathcal{N}(\mu, \Sigma)$ 。矩阵 $\Lambda := \Sigma^{-1}$ 称为精度矩阵。

要说明这个定义是合理的，需要验证三件事：它确实是一个概率密度（积分为 1）；它的均值确实是 μ ；它的协方差确实是 Σ 。

3.2 归一化常数的推导

命题 3.2. $\int_{\mathbb{R}^n} \exp\left(-\frac{1}{2}(\mathbf{x} - \mu)^\top \Sigma^{-1}(\mathbf{x} - \mu)\right) d\mathbf{x} = (2\pi)^{n/2} (\det \Sigma)^{1/2}$ 。

证明. 思路是用谱定理把二次型对角化，把 n 重积分化为 n 个一元高斯积分之积。

由谱定理， $\Sigma = Q\Lambda Q^\top$ ， $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$ ， $\lambda_i > 0$ 。作换元

$$\mathbf{x} - \mu = Q\Lambda^{1/2}\mathbf{w}, \quad \text{即} \quad \mathbf{x} = \Sigma^{1/2}Q\mathbf{w} + \mu \quad (\text{也可直接取 } \mathbf{x} = Q\Lambda^{1/2}\mathbf{w} + \mu).$$

按定理 2.14， $d\mathbf{x} = |\det(Q\Lambda^{1/2})| d\mathbf{w} = \prod_i \sqrt{\lambda_i} d\mathbf{w} = (\det \Sigma)^{1/2} d\mathbf{w}$ （用到 $|\det Q| = 1$ ）。而

$$(\mathbf{x} - \mu)^\top \Sigma^{-1}(\mathbf{x} - \mu) = \mathbf{w}^\top \Lambda^{1/2} Q^\top Q \Lambda^{-1} Q^\top Q \Lambda^{1/2} \mathbf{w} = \mathbf{w}^\top \mathbf{w} = \sum_{i=1}^n w_i^2.$$

于是

$$\begin{aligned} \int_{\mathbb{R}^n} e^{-\frac{1}{2}(\mathbf{x}-\mu)^\top \Sigma^{-1}(\mathbf{x}-\mu)} d\mathbf{x} &= (\det \Sigma)^{1/2} \int_{\mathbb{R}^n} e^{-\frac{1}{2} \sum_i w_i^2} d\mathbf{w} \\ &= (\det \Sigma)^{1/2} \prod_{i=1}^n \int_{\mathbb{R}} e^{-w_i^2/2} dw_i = (\det \Sigma)^{1/2} (2\pi)^{n/2}. \end{aligned}$$

□

上面证明中的换元 $\mathbf{w} = \Lambda^{-1/2}Q^\top(\mathbf{x} - \mu)$ 称为**白化**：它把一般的高斯变量变成各分量独立的标准正态变量。反过来说，任何多元高斯变量都可以写成 $\mathbf{x} = \mu + \Sigma^{1/2}\mathbf{w}$ ，其中 $\mathbf{w} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 。这一观点使得均值与协方差的计算变得非常简单。

3.3 均值与协方差

命题 3.3. 若 $\mathbf{x} \sim \mathcal{N}(\mu, \Sigma)$ ，则 $\mathbb{E}[\mathbf{x}] = \mu$ ， $\text{Cov}[\mathbf{x}] = \Sigma$ 。

证明. 先处理标准情形 $\mathbf{w} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ ：其密度 $\prod_i (2\pi)^{-1/2} e^{-w_i^2/2}$ 是各分量密度之积，故各 w_i 独立同分布于 $\mathcal{N}(0, 1)$ ，于是 $\mathbb{E}[\mathbf{w}] = \mathbf{0}$ ， $\text{Cov}[\mathbf{w}] = \mathbb{E}[\mathbf{w}\mathbf{w}^\top] = \mathbf{I}$ （对角元 $\mathbb{E}[w_i^2] = 1$ ，非对角元 $\mathbb{E}[w_i w_j] = \mathbb{E}[w_i] \mathbb{E}[w_j] = 0$ ）。

一般情形，由 (5) 反推： $\mathbf{x} = \Sigma^{1/2}\mathbf{w} + \mu$ 的密度恰为 (6)（读者可代入验证，注意 $|\det \Sigma^{1/2}| = (\det \Sigma)^{1/2}$ ）。因此

$$\mathbb{E}[\mathbf{x}] = \Sigma^{1/2} \mathbb{E}[\mathbf{w}] + \mu = \mu, \quad \text{Cov}[\mathbf{x}] = \mathbb{E}[\Sigma^{1/2} \mathbf{w} \mathbf{w}^\top \Sigma^{1/2}] = \Sigma^{1/2} \mathbf{I} \Sigma^{1/2} = \Sigma.$$

□

3.4 仿射变换保持高斯性

定理 3.4 (仿射变换). 设 $\mathbf{x} \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, $\mathbf{x} \in \mathbb{R}^n$, $\mathbf{A} \in \mathbb{R}^{k \times n}$ 行满秩 ($k \leq n$), $\mathbf{b} \in \mathbb{R}^k$. 则

$$\mathbf{Ax} + \mathbf{b} \sim \mathcal{N}(\mathbf{A}\boldsymbol{\mu} + \mathbf{b}, \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^\top).$$

证明. 均值与协方差直接由线性性得到: $\mathbb{E}[\mathbf{Ax} + \mathbf{b}] = \mathbf{A}\boldsymbol{\mu} + \mathbf{b}$, $\text{Cov}[\mathbf{Ax} + \mathbf{b}] = \mathbf{A} \text{Cov}[\mathbf{x}] \mathbf{A}^\top = \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^\top$, 且由命题 2.5(4), $\mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^\top = (\mathbf{A}\boldsymbol{\Sigma}^{1/2})(\mathbf{A}\boldsymbol{\Sigma}^{1/2})^\top \succ 0$.

剩下要证的是分布仍为高斯。若 $k = n$ ($\mathbf{A}$ 可逆), 由 (5), $\mathbf{y} = \mathbf{Ax} + \mathbf{b}$ 的密度为

$$\begin{aligned} & \frac{1}{|\det \mathbf{A}|} \mathcal{N}(\mathbf{A}^{-1}(\mathbf{y} - \mathbf{b}); \boldsymbol{\mu}, \boldsymbol{\Sigma}) \\ &= \frac{1}{(2\pi)^{n/2} |\det \mathbf{A}| (\det \boldsymbol{\Sigma})^{1/2}} \exp \left(-\frac{1}{2} (\mathbf{y} - \mathbf{A}\boldsymbol{\mu} - \mathbf{b})^\top \mathbf{A}^{-\top} \boldsymbol{\Sigma}^{-1} \mathbf{A}^{-1} (\mathbf{y} - \mathbf{A}\boldsymbol{\mu} - \mathbf{b}) \right), \end{aligned}$$

其中我们用了 $\mathbf{A}^{-1}(\mathbf{y} - \mathbf{b}) - \boldsymbol{\mu} = \mathbf{A}^{-1}(\mathbf{y} - \mathbf{A}\boldsymbol{\mu} - \mathbf{b})$ 。注意 $\mathbf{A}^{-\top} \boldsymbol{\Sigma}^{-1} \mathbf{A}^{-1} = (\mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^\top)^{-1}$, 且 $|\det \mathbf{A}| (\det \boldsymbol{\Sigma})^{1/2} = (\det(\mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^\top))^{1/2}$, 这正是 $\mathcal{N}(\mathbf{y}; \mathbf{A}\boldsymbol{\mu} + \mathbf{b}, \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^\top)$ 。

若 $k < n$, 把 $\mathbf{A}$ 补成可逆方阵 $\tilde{\mathbf{A}} = \begin{pmatrix} \mathbf{A} \\ \mathbf{A}' \end{pmatrix}$ (在 $\mathbf{A}$ 的行空间的正交补中任选 $n - k$ 个线性无关的行), 则 $\tilde{\mathbf{A}}\mathbf{x} + \tilde{\mathbf{b}}$ 是 n 维高斯, 而 $\mathbf{Ax} + \mathbf{b}$ 是它的前 k 个分量, 即它的一个边缘分布。边缘分布仍是高斯这一事实将在定理 4.2 中证明 (那里的证明不依赖本定理)。□

注 3.5. 定理 3.4 说明: 高斯族在仿射变换下封闭, 且只需追踪均值与协方差这两个量。这是高斯分布在概率论、统计和机器学习中如此好用的根本原因。

3.5 几何图像

密度 (6) 的等高线由 $(\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) = c$ 给出。由 (1), 在以 $\boldsymbol{\mu}$ 为原点、以特征向量 $\mathbf{q}_i$ 为坐标轴的坐标系下, 这个方程是 $\sum_i w_i^2 / \lambda_i = c$, 即一个椭圆: 主轴方向是 $\boldsymbol{\Sigma}$ 的特征向量, 半轴长与 $\sqrt{\lambda_i}$ 成比例。协方差越大的方向, 分布越“扁长”。

4 两个高维随机变量的联合高斯分布 $P(\mathbf{x}, \mathbf{y})$

4.1 设定与联合密度

现在设 $\mathbf{x} \in \mathbb{R}^n$, $\mathbf{y} \in \mathbb{R}^m$, 并把它们拼成一个 $(n + m)$ 维向量

$$\mathbf{z} = \begin{pmatrix} \mathbf{x} \\ \mathbf{y} \end{pmatrix} \in \mathbb{R}^{n+m}.$$

所谓“ $\mathbf{x}$ 与 $\mathbf{y}$ 联合高斯”, 就是指 $\mathbf{z} \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ 。把均值与协方差按同样方式分块:

$$\boldsymbol{\mu} = \begin{pmatrix} \boldsymbol{\mu}_x \\ \boldsymbol{\mu}_y \end{pmatrix}, \quad \boldsymbol{\Sigma} = \begin{pmatrix} \boldsymbol{\Sigma}_{xx} & \boldsymbol{\Sigma}_{xy} \\ \boldsymbol{\Sigma}_{yx} & \boldsymbol{\Sigma}_{yy} \end{pmatrix}, \quad \boldsymbol{\Sigma}_{xx} \in \mathbb{R}^{n \times n}, \boldsymbol{\Sigma}_{yy} \in \mathbb{R}^{m \times m}, \boldsymbol{\Sigma}_{yx} = \boldsymbol{\Sigma}_{xy}^\top. \quad (7)$$

这里 $\mu_x = \mathbb{E}[\mathbf{x}]$, $\mu_y = \mathbb{E}[\mathbf{y}]$, $\Sigma_{xx} = \text{Cov}[\mathbf{x}]$, $\Sigma_{yy} = \text{Cov}[\mathbf{y}]$, $\Sigma_{xy} = \text{Cov}[\mathbf{x}, \mathbf{y}]$ 。

于是联合密度的表达式就是把 (6) 写在 $\mathbf{z}$ 上:

$$P(\mathbf{x}, \mathbf{y}) = \frac{1}{(2\pi)^{(n+m)/2} (\det \Sigma)^{1/2}} \exp \left(-\frac{1}{2} \begin{pmatrix} \mathbf{x} - \mu_x \\ \mathbf{y} - \mu_y \end{pmatrix}^\top \begin{pmatrix} \Sigma_{xx} & \Sigma_{xy} \\ \Sigma_{yx} & \Sigma_{yy} \end{pmatrix}^{-1} \begin{pmatrix} \mathbf{x} - \mu_x \\ \mathbf{y} - \mu_y \end{pmatrix} \right). \quad (8)$$

写下它并不困难，真正有内容的问题是：这个分块矩阵的逆是什么？指数如何展开？由此能读出什么？以下逐步回答。

4.2 第一步：用 Schur 补写出精度矩阵

记精度矩阵 $\Lambda = \Sigma^{-1}$ 并同样分块为 $\begin{pmatrix} \Lambda_{xx} & \Lambda_{xy} \\ \Lambda_{yx} & \Lambda_{yy} \end{pmatrix}$ 。由命题 2.11, $\Sigma_{xx} \succ 0$, 且 Schur 补

$$\mathbf{S} := \Sigma_{yy} - \Sigma_{yx} \Sigma_{xx}^{-1} \Sigma_{xy} \succ 0. \quad (9)$$

把定理 2.10 用于 Σ (取 $A = \Sigma_{xx}$, $B = \Sigma_{xy}$, $C = \Sigma_{yx}$, $D = \Sigma_{yy}$) 得到

$$\begin{aligned} \Lambda_{xx} &= \Sigma_{xx}^{-1} + \Sigma_{xx}^{-1} \Sigma_{xy} \mathbf{S}^{-1} \Sigma_{yx} \Sigma_{xx}^{-1}, & \Lambda_{xy} &= -\Sigma_{xx}^{-1} \Sigma_{xy} \mathbf{S}^{-1}, \\ \Lambda_{yx} &= -\mathbf{S}^{-1} \Sigma_{yx} \Sigma_{xx}^{-1}, & \Lambda_{yy} &= \mathbf{S}^{-1}. \end{aligned} \quad (10)$$

同时由定理 2.9,

$$\det \Sigma = \det \Sigma_{xx} \cdot \det \mathbf{S}. \quad (11)$$

注 4.1. (10) 中最值得注意的是 $\Lambda_{yy} = \mathbf{S}^{-1}$: 精度矩阵的一个对角块, 等于协方差矩阵中对应块的 Schur 补的逆, 而不等于 Σ_{yy}^{-1} 。这一点在后面解释“条件协方差”时会再出现。

4.3 第二步：展开指数

令 $\mathbf{u} = \mathbf{x} - \mu_x$, $\mathbf{v} = \mathbf{y} - \mu_y$ 。指数中的二次型是

$$\Delta^2 := \begin{pmatrix} \mathbf{u} \\ \mathbf{v} \end{pmatrix}^\top \Sigma^{-1} \begin{pmatrix} \mathbf{u} \\ \mathbf{v} \end{pmatrix}.$$

把命题 2.13 直接套用于 $M = \Sigma$, 得到

$$\Delta^2 = \underbrace{\mathbf{u}^\top \Sigma_{xx}^{-1} \mathbf{u}}_{\text{只含 } x} + \underbrace{(\mathbf{v} - \Sigma_{yx} \Sigma_{xx}^{-1} \mathbf{u})^\top \mathbf{S}^{-1} (\mathbf{v} - \Sigma_{yx} \Sigma_{xx}^{-1} \mathbf{u})}_{\text{关于 } y \text{ 的完全平方}}. \quad (12)$$

为了让读者看到“配方”是如何发生的, 这里再给出一个不借助命题 2.13、而是直接用精度矩阵分块 (10) 和引理 2.12 的推导。按块展开:

$$\Delta^2 = \mathbf{u}^\top \Lambda_{xx} \mathbf{u} + 2\mathbf{u}^\top \Lambda_{xy} \mathbf{v} + \mathbf{v}^\top \Lambda_{yy} \mathbf{v}.$$

把它看作 $\mathbf{v}$ 的二次函数: $\mathbf{v}^\top \Lambda_{yy} \mathbf{v} + 2(\Lambda_{yx} \mathbf{u})^\top \mathbf{v}$, 由引理 2.12 ($D = \Lambda_{yy}$, $\mathbf{b} = \Lambda_{yx} \mathbf{u}$):

$$\mathbf{v}^\top \Lambda_{yy} \mathbf{v} + 2(\Lambda_{yx} \mathbf{u})^\top \mathbf{v} = (\mathbf{v} + \Lambda_{yy}^{-1} \Lambda_{yx} \mathbf{u})^\top \Lambda_{yy} (\mathbf{v} + \Lambda_{yy}^{-1} \Lambda_{yx} \mathbf{u}) - \mathbf{u}^\top \Lambda_{xy} \Lambda_{yy}^{-1} \Lambda_{yx} \mathbf{u}.$$

代入 (10): $\Lambda_{yy}^{-1} \Lambda_{yx} = -\mathbf{S} \mathbf{S}^{-1} \Sigma_{yx} \Sigma_{xx}^{-1} = -\Sigma_{yx} \Sigma_{xx}^{-1}$, 所以完全平方项的中心是 $\mathbf{v} - \Sigma_{yx} \Sigma_{xx}^{-1} \mathbf{u}$, 精度是 $\Lambda_{yy} = \mathbf{S}^{-1}$ 。剩余部分为

$$\begin{aligned} \mathbf{u}^\top (\Lambda_{xx} - \Lambda_{xy} \Lambda_{yy}^{-1} \Lambda_{yx}) \mathbf{u} &= \mathbf{u}^\top \left(\Sigma_{xx}^{-1} + \Sigma_{xx}^{-1} \Sigma_{xy} \mathbf{S}^{-1} \Sigma_{yx} \Sigma_{xx}^{-1} - \Sigma_{xx}^{-1} \Sigma_{xy} \mathbf{S}^{-1} \mathbf{S} \mathbf{S}^{-1} \Sigma_{yx} \Sigma_{xx}^{-1} \right) \mathbf{u} \\ &= \mathbf{u}^\top \Sigma_{xx}^{-1} \mathbf{u}, \end{aligned}$$

与 (12) 一致。顺便注意到一个对偶的事实: $\Lambda_{xx} - \Lambda_{xy} \Lambda_{yy}^{-1} \Lambda_{yx} = \Sigma_{xx}^{-1}$, 即精度矩阵的 Schur 补等于协方差矩阵对应块的逆。

4.4 第三步: 联合密度的乘积分解

把 (12) 与 (11) 代回 (8), 并把常数按 $(2\pi)^{(n+m)/2} = (2\pi)^{n/2} (2\pi)^{m/2}$ 拆开:

$$\begin{aligned} P(\mathbf{x}, \mathbf{y}) &= \frac{1}{(2\pi)^{n/2} (\det \Sigma_{xx})^{1/2}} \exp \left(-\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_x)^\top \Sigma_{xx}^{-1} (\mathbf{x} - \boldsymbol{\mu}_x) \right) \\ &\quad \times \frac{1}{(2\pi)^{m/2} (\det \mathbf{S})^{1/2}} \exp \left(-\frac{1}{2} (\mathbf{y} - \boldsymbol{\mu}_{y|x})^\top \mathbf{S}^{-1} (\mathbf{y} - \boldsymbol{\mu}_{y|x}) \right), \end{aligned} \quad (13)$$

其中

$$\boldsymbol{\mu}_{y|x} := \boldsymbol{\mu}_y + \Sigma_{yx} \Sigma_{xx}^{-1} (\mathbf{x} - \boldsymbol{\mu}_x). \quad (14)$$

也就是说,

$$P(\mathbf{x}, \mathbf{y}) = \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_x, \Sigma_{xx}) \cdot \mathcal{N}(\mathbf{y}; \boldsymbol{\mu}_y + \Sigma_{yx} \Sigma_{xx}^{-1} (\mathbf{x} - \boldsymbol{\mu}_x), \Sigma_{yy} - \Sigma_{yx} \Sigma_{xx}^{-1} \Sigma_{xy}). \quad (15)$$

这个式子是本讲义的中心结论, 下面两个定理只是对它的解读。

4.5 边缘分布

定理 4.2 (边缘分布). 若 $\begin{pmatrix} \mathbf{x} \\ \mathbf{y} \end{pmatrix} \sim \mathcal{N}\left(\begin{pmatrix} \boldsymbol{\mu}_x \\ \boldsymbol{\mu}_y \end{pmatrix}, \begin{pmatrix} \Sigma_{xx} & \Sigma_{xy} \\ \Sigma_{yx} & \Sigma_{yy} \end{pmatrix}\right)$, 则

$$P(\mathbf{x}) = \int_{\mathbb{R}^m} P(\mathbf{x}, \mathbf{y}) d\mathbf{y} = \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_x, \Sigma_{xx}), \quad P(\mathbf{y}) = \mathcal{N}(\mathbf{y}; \boldsymbol{\mu}_y, \Sigma_{yy}).$$

证明. 对 (15) 关于 $\mathbf{y}$ 积分。第一个因子与 $\mathbf{y}$ 无关; 第二个因子是关于 $\mathbf{y}$ 的高斯密度 $\mathcal{N}(\mathbf{y}; \boldsymbol{\mu}_{y|x}, \mathbf{S})$ ($\mathbf{S} \succ 0$ 已由 (9) 保证, 而 $\boldsymbol{\mu}_{y|x}$ 只是一个依赖于 $\mathbf{x}$ 的常向量), 由命题 3.2 其积分为 1。故 $P(\mathbf{x}) = \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_x, \Sigma_{xx})$ 。对 $P(\mathbf{y})$, 交换 $\mathbf{x}, \mathbf{y}$ 的角色 (即对 Σ_{yy} 取 Schur 补) 即可。□

结论非常直观: 高斯向量的一部分分量仍是高斯的, 其均值与协方差就是原均值、协方差中对应的块——直接“读”出来即可, 不需要任何计算。

4.6 条件分布

定理 4.3 (条件分布). 在定理 4.2 的设定下,

$$P(\mathbf{y} | \mathbf{x}) = \mathcal{N}(\mathbf{y}; \boldsymbol{\mu}_{y|x}, \boldsymbol{\Sigma}_{y|x}), \quad \begin{cases} \boldsymbol{\mu}_{y|x} = \boldsymbol{\mu}_y + \boldsymbol{\Sigma}_{yx} \boldsymbol{\Sigma}_{xx}^{-1} (\mathbf{x} - \boldsymbol{\mu}_x), \\ \boldsymbol{\Sigma}_{y|x} = \boldsymbol{\Sigma}_{yy} - \boldsymbol{\Sigma}_{yx} \boldsymbol{\Sigma}_{xx}^{-1} \boldsymbol{\Sigma}_{xy} = \boldsymbol{\Lambda}_{yy}^{-1}. \end{cases} \quad (16)$$

证明. 由定义 $P(\mathbf{y} | \mathbf{x}) = P(\mathbf{x}, \mathbf{y})/P(\mathbf{x})$, 用 (15) 与定理 4.2 相除, 第一个因子恰好约去。□

对 (16) 的几点解读:

1. **条件均值是 $\mathbf{x}$ 的仿射函数。** 系数矩阵 $\boldsymbol{\Sigma}_{yx} \boldsymbol{\Sigma}_{xx}^{-1}$ 正是“用 $\mathbf{x}$ 线性回归 $\mathbf{y}$ ”的最优系数; $\mathbf{x}$ 偏离其均值多少, 就按这个矩阵成比例地修正对 $\mathbf{y}$ 的预期。
2. **条件协方差不依赖于 $\mathbf{x}$ 的取值,** 且 $\boldsymbol{\Sigma}_{y|x} \preceq \boldsymbol{\Sigma}_{yy}$ (因为 $\boldsymbol{\Sigma}_{yx} \boldsymbol{\Sigma}_{xx}^{-1} \boldsymbol{\Sigma}_{xy} \succeq 0$): 观测到 $\mathbf{x}$ 之后, 关于 $\mathbf{y}$ 的不确定性只会减少或不变。
3. **用精度矩阵表述更简洁:** $\boldsymbol{\Sigma}_{y|x} = \boldsymbol{\Lambda}_{yy}^{-1}$, $\boldsymbol{\mu}_{y|x} = \boldsymbol{\mu}_y - \boldsymbol{\Lambda}_{yy}^{-1} \boldsymbol{\Lambda}_{yx} (\mathbf{x} - \boldsymbol{\mu}_x)$ 。这说明精度矩阵“天然适合”描述条件分布, 而协方差矩阵“天然适合”描述边缘分布。

4.7 独立性

推论 4.4. 联合高斯的 $\mathbf{x}$ 与 $\mathbf{y}$ 相互独立, 当且仅当 $\boldsymbol{\Sigma}_{xy} = \mathbf{0}$ (不相关)。

证明. 若 $\boldsymbol{\Sigma}_{xy} = \mathbf{0}$, 则 (15) 中 $\boldsymbol{\mu}_{y|x} = \boldsymbol{\mu}_y$, $\boldsymbol{S} = \boldsymbol{\Sigma}_{yy}$, 联合密度化为 $\mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_x, \boldsymbol{\Sigma}_{xx}) \mathcal{N}(\mathbf{y}; \boldsymbol{\mu}_y, \boldsymbol{\Sigma}_{yy}) = P(\mathbf{x})P(\mathbf{y})$ 。反之独立蕴含不相关对任何分布都成立。□

注 4.5. “不相关 $\Rightarrow$ 独立”对一般分布不成立, 它是高斯分布的特殊性质。此外, “ $\mathbf{x}$ 、 $\mathbf{y}$ 各自高斯”并不能推出“ $(\mathbf{x}, \mathbf{y})$ 联合高斯”, 联合高斯是一个更强的假设。

5 例子与应用

5.1 二维情形: $n = m = 1$

取 x, y 为标量, $\text{Var}(x) = \sigma_1^2$, $\text{Var}(y) = \sigma_2^2$, 相关系数 $\rho \in (-1, 1)$, 即

$$\boldsymbol{\mu} = \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}, \quad \boldsymbol{\Sigma} = \begin{pmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix}.$$

则 $\det \boldsymbol{\Sigma} = \sigma_1^2 \sigma_2^2 (1 - \rho^2)$,

$$\boldsymbol{\Sigma}^{-1} = \frac{1}{1 - \rho^2} \begin{pmatrix} 1/\sigma_1^2 & -\rho/(\sigma_1\sigma_2) \\ -\rho/(\sigma_1\sigma_2) & 1/\sigma_2^2 \end{pmatrix},$$

代入 (8) 得到熟悉的二元正态密度

$$P(x, y) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp \left\{ -\frac{1}{2(1-\rho^2)} \left[\frac{(x-\mu_1)^2}{\sigma_1^2} - \frac{2\rho(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2} + \frac{(y-\mu_2)^2}{\sigma_2^2} \right] \right\}.$$

用定理 4.3: Schur 补 $S = \sigma_2^2 - \rho^2 \sigma_1^2 \sigma_2^2 / \sigma_1^2 = \sigma_2^2(1 - \rho^2)$, 回归系数 $\Sigma_{yx} \Sigma_{xx}^{-1} = \rho \sigma_2 / \sigma_1$, 故

$$y | x \sim \mathcal{N}\left(\mu_2 + \rho \frac{\sigma_2}{\sigma_1}(x - \mu_1), \sigma_2^2(1 - \rho^2)\right).$$

$|\rho|$ 越接近 1, 知道 x 后对 y 的不确定性 $\sigma_2^2(1 - \rho^2)$ 越小, 这与直觉一致。

5.2 线性高斯模型：如何”制造”一个联合高斯

实际问题中, 联合分布往往不是直接给出的, 而是通过”先验 + 观测模型”构造出来的。设

$$\mathbf{x} \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma}), \quad \mathbf{y} = \mathbf{A}\mathbf{x} + \mathbf{b} + \boldsymbol{\varepsilon}, \quad \boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{L}^{-1}), \quad \boldsymbol{\varepsilon} \text{ 与 } \mathbf{x} \text{ 独立},$$

其中 $\mathbf{A} \in \mathbb{R}^{m \times n}$, $\mathbf{L} \succ 0$ 是噪声精度。这等价于说 $P(\mathbf{y} | \mathbf{x}) = \mathcal{N}(\mathbf{y}; \mathbf{A}\mathbf{x} + \mathbf{b}, \mathbf{L}^{-1})$ 。

命题 5.1. 在上述模型下, $(\mathbf{x}, \mathbf{y})$ 联合高斯, 且

$$\begin{pmatrix} \mathbf{x} \\ \mathbf{y} \end{pmatrix} \sim \mathcal{N}\left(\begin{pmatrix} \boldsymbol{\mu} \\ \mathbf{A}\boldsymbol{\mu} + \mathbf{b} \end{pmatrix}, \begin{pmatrix} \boldsymbol{\Sigma} & \boldsymbol{\Sigma}\mathbf{A}^\top \\ \mathbf{A}\boldsymbol{\Sigma} & \mathbf{L}^{-1} + \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^\top \end{pmatrix}\right).$$

证明. $\mathbf{x}$ 与 $\boldsymbol{\varepsilon}$ 独立且各自高斯, 故 $\begin{pmatrix} \mathbf{x} \\ \boldsymbol{\varepsilon} \end{pmatrix} \sim \mathcal{N}\left(\begin{pmatrix} \boldsymbol{\mu} \\ \mathbf{0} \end{pmatrix}, \begin{pmatrix} \boldsymbol{\Sigma} & \mathbf{0} \\ \mathbf{0} & \mathbf{L}^{-1} \end{pmatrix}\right)$ (两个独立高斯密度之积正是分块对角协方差的联合高斯密度)。而

$$\begin{pmatrix} \mathbf{x} \\ \mathbf{y} \end{pmatrix} = \begin{pmatrix} \mathbf{I} & \mathbf{0} \\ \mathbf{A} & \mathbf{I} \end{pmatrix} \begin{pmatrix} \mathbf{x} \\ \boldsymbol{\varepsilon} \end{pmatrix} + \begin{pmatrix} \mathbf{0} \\ \mathbf{b} \end{pmatrix}$$

是一个可逆仿射变换, 由定理 3.4 结果仍为高斯, 其均值与协方差按 $\mathbf{A}\boldsymbol{\mu} + \mathbf{b}$ 、 $\mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^\top$ 的规则计算:

$$\begin{pmatrix} \mathbf{I} & \mathbf{0} \\ \mathbf{A} & \mathbf{I} \end{pmatrix} \begin{pmatrix} \boldsymbol{\Sigma} & \mathbf{0} \\ \mathbf{0} & \mathbf{L}^{-1} \end{pmatrix} \begin{pmatrix} \mathbf{I} & \mathbf{A}^\top \\ \mathbf{0} & \mathbf{I} \end{pmatrix} = \begin{pmatrix} \boldsymbol{\Sigma} & \boldsymbol{\Sigma}\mathbf{A}^\top \\ \mathbf{A}\boldsymbol{\Sigma} & \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^\top + \mathbf{L}^{-1} \end{pmatrix}.$$

□

有了联合分布, 就可以反过来用定理 4.3 求”看到 $\mathbf{y}$ 之后 $\mathbf{x}$ 是什么”, 即贝叶斯后验:

$$P(\mathbf{x} | \mathbf{y}) = \mathcal{N}(\mathbf{x}; \boldsymbol{\mu} + \mathbf{K}(\mathbf{y} - \mathbf{A}\boldsymbol{\mu} - \mathbf{b}), \boldsymbol{\Sigma} - \mathbf{K}\mathbf{A}\boldsymbol{\Sigma}), \quad \mathbf{K} := \boldsymbol{\Sigma}\mathbf{A}^\top(\mathbf{L}^{-1} + \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^\top)^{-1}.$$

这正是卡尔曼滤波更新步、高斯过程回归、贝叶斯线性回归等算法的公共核心。矩阵 $\mathbf{K}$ 通常称为增益矩阵。

6 小结

- 联合高斯 $P(\mathbf{x}, \mathbf{y})$ 的表达式只是把多元高斯密度写在拼接向量 $\mathbf{z} = (\mathbf{x}, \mathbf{y})$ 上, 并把均值与协方差分块。

- 一切推导归结为分块对称正定矩阵的两个事实： $\det \Sigma = \det \Sigma_{xx} \det S$ ，以及二次型的 Schur 分解 (4)。两者都来自分块 LDU 分解 (2)。
- 由此得到乘积分解 $P(\mathbf{x}, \mathbf{y}) = P(\mathbf{x})P(\mathbf{y} | \mathbf{x})$ ，其中边缘分布”直接读块”，条件分布”均值线性修正、协方差取 Schur 补”。
- 协方差矩阵方便描述边缘，精度矩阵方便描述条件： $\Sigma_{y|x} = \Lambda_{yy}^{-1}$ ， $P(\mathbf{y})$ 的协方差是 Σ_{yy} 。

练习

1. 验证命题 2.13 中 $\mathbf{L}^{-1} \begin{pmatrix} \mathbf{u} \\ \mathbf{v} \end{pmatrix}$ 的计算，并说明为什么它对应”用 $\mathbf{x}$ 的信息消去 $\mathbf{y}$ 中与 $\mathbf{x}$ 相关的部分”。
2. 对 Σ_{yy} 取 Schur 补，写出 $P(\mathbf{x} | \mathbf{y})$ 的均值与协方差，并与 (16) 对照。
3. 设 $\mathbf{x} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_n)$ ， $y = \mathbf{a}^\top \mathbf{x}$ ($\mathbf{a} \neq \mathbf{0}$)。求 $P(\mathbf{x} | y)$ ，并解释条件协方差 $\mathbf{I} - \mathbf{a}\mathbf{a}^\top / \|\mathbf{a}\|^2$ 的几何意义。
4. 证明 $\Lambda_{xx} - \Lambda_{xy}\Lambda_{yy}^{-1}\Lambda_{yx} = \Sigma_{xx}^{-1}$ ，即对精度矩阵取 Schur 补得到协方差块的逆。
5. 在线性高斯模型中，利用分块求逆公式 (3) 证明后验协方差也可写为 $(\Sigma^{-1} + \mathbf{A}^\top \mathbf{L} \mathbf{A})^{-1}$ ，后验均值可写为 $(\Sigma^{-1} + \mathbf{A}^\top \mathbf{L} \mathbf{A})^{-1}(\mathbf{A}^\top \mathbf{L}(\mathbf{y} - \mathbf{b}) + \Sigma^{-1}\boldsymbol{\mu})$ 。(提示：这就是 Woodbury 恒等式。)